UNIVERSITÀ POLITECNICA DELLE MARCHE
FACOLTÀ DI INGEGNERIA
Dipartimento di Ingegneria dell'Informazione
Corso di Laurea Magistrale in Ingegneria Informatica e dell'Automazione



TESI DI LAUREA

Applicazione di tecniche di Data Science per l'analisi dell'efficacia delle promozioni relative ad un'azienda produttrice di articoli per la cura della persona

Application of Data Science techniques for the analysis of the effectiveness of the promotions for a company producing personal care items

Relatore

Prof. Domenico Ursino

Candidato

Bogdan Petru Borc

ANNO ACCADEMICO 2020-2021

Ogni cosa era più sua che di ogni altro la terra, l'aria, l'acqua non hanno padroni
ma sono di tutti gli uomini, o meglio di chi sa farsi
terra, aria, acqua e sentirsi parte di tutto il creato

Mario Rigoni Stern, "Stagioni"

Sommario

Negli ultimi anni la Customer Analytics ha assunto un'importanza sempre maggiore, in quanto, riuscendo a capire i comportamenti dei clienti e le loro preferenze, permette di prendere decisioni strategiche e tattiche. Le promozioni giocano un ruolo importantissimo nel soddisfare ed attirare nuovi clienti. In questa tesi sono stati analizzati i dati relativi alle promozioni ed alle vendite dell'azienda Fater. In particolare è stata realizzata una fase di ETL dei dati, seguita da un'analisi descrittiva. Successivamente è stata effettuata una fase di clustering, seguita da una di classificazione, per valutare quanto le promozioni abbiano influenzato le vendite.

Keyword: Data Analytics, Customer Analytics, Promozioni, Extract Trasform and Load, Exploratory Data Analysis, Cluster, Classificazione, Pandas

Indice

1 Analisi descrittiva del dataset **1**
- 1.1 Panoramica Generale e Obiettivi dello Studio . . . 1
- 1.2 Catalogo Completo delle 58 Feature e Tipologia dei Dati . . . 2
- 1.3 Analisi di Data Quality: Confronto tra Dataset Grezzo (`usage`) e Validato (`users`) . . . 5
- 1.4 Definizione del Perimetro sui Minorenni ($N = 146.258$) e Preparazione del Dataset . . . 6

2 Minors' Lifestyle Analysis: classificazione **8**
- 2.1 Selezione delle feature e pulizia del dataset . . . 8
- 2.2 Preprocessing del dataset . . . 9
  - 2.2.1 Bilanciamento del dataset . . . 9
  - 2.2.2 Dataset Finale . . . 10
  - 2.2.3 Analisi della distribuzione degli attributi . . . 11
- 2.3 Scenari di Classificazione . . . 12
- 2.4 Processo di Classificazione . . . 12
  - 2.4.1 Ottimizzazione dei Modelli . . . 13
- 2.5 Competenze del committente . . . 13
- 2.6 Domanda e relazione tecnica preliminare . . . 15
  - 2.6.1 Per sistemi open loop . . . 15
  - 2.6.2 Per sistemi closed loop . . . 16
  - 2.6.3 Compiti della direzione lavori . . . 16
- 2.7 Relazione tecnica finale . . . 17
  - 2.7.1 Per sistemi open loop . . . 17
  - 2.7.2 Per sistemi closed loop . . . 17

3 Minors' Lifestyle Analysis: clustering **18**
- 3.1 Introduzione e Obiettivo del Clustering . . . 18
- 3.2 Caricamento del Dataset e Selezione Iniziale delle Feature . . . 18
- 3.3 Analisi Esplorativa dei Dati (EDA) . . . 19
  - 3.3.1 Interpretazione delle Distribuzioni Univariate . . . 20
  - 3.3.2 Analisi Bivariata: Esposizione a Instagram e Indicatori di Salute Mentale 20
- 3.4 Analisi delle Relazioni tra le Variabili e Scrematura della Multicollinearità . . 21
- 3.5 Standardizzazione (`StandardScaler`) e Scelta del Valore Ottimo per la `PCA` 23
  - 3.5.1 Standardizzazione Z-Score e Verifica di Non-Falsatura della PCA . . . 23

3.5.2 Interpretazione Semantica delle 5 Componenti Principali (`PC1–PC5`) . 25
3.6 Algoritmo 1 — Clustering Partizionale con `K-Means` 26
3.6.1 Ricerca del Numero Ottimo di Cluster (k) 26
3.6.2 Visualizzazione Geometrica dei Cluster K-Means ($k = 3$): 2D PCA, 3D PCA e Proiezione Supervisionata LDA 26
3.6.3 Profilazione Completa dei Cluster K-Means ($k = 3$): Heatmap, Radar Chart e Identikit delle User Personas 27
3.6.4 Approfondimento a $k = 4$ Cluster e Validazione Incrociata con le Classi di Rischio Stress 28
3.7 Algoritmo 2 — Clustering Basato su Densità con `DBSCAN` 28
3.7.1 Metodologia, k-Distance Plot e Grid Search Bivariata (`eps` × `min_samples`) 28
3.7.2 Visualizzazione Geometrica di DBSCAN e Caratterizzazione degli Outlier (`-1`) 29
3.8 Algoritmo 3 — Clustering Gerarchico a Densità Variabile con `HDBSCAN` e Confronto Finale 30
3.8.1 Applicazione di HDBSCAN: Metodo `EOM` (*Excess of Mass*) contro Metodo `Leaf` 30
3.8.2 Discussione Critica e Confronto Finale tra i 3 Algoritmi 30

4 Proposta per un iter autorizzativo **32**
4.1 Competenze dell'ente di controllo 32
4.1.1 Pianificazione territoriale 33
4.1.2 Disciplinare 33
4.2 Competenze del committente 33
4.3 Domanda e relazione tecnica preliminare 35
4.3.1 Per sistemi open loop 35
4.3.2 Per sistemi closed loop 36
4.3.3 Compiti della direzione lavori 36
4.4 Relazione tecnica finale 37
4.4.1 Per sistemi open loop 37
4.4.2 Per sistemi closed loop 37

Bibliografia **38**

Sitografia **43**

Ringraziamenti **45**

Elenco delle figure

1.1 Panoramica demografica dell'intero dataset ($N = 1.547.896$ utenti, 13–65 anni): distribuzione per età con isolamento della coorte dei minorenni ($N = 146.258$, $9,45\%$), ripartizione per contesto abitativo e genere, e andamento del tempo attivo medio su Instagram e dello stress percepito per fascia d'età. 2

1.2 Impatto della validazione dei dati sui 146.258 minorenni (13–17 anni): confronto tra il file grezzo (`usage`, in arancione) e il file validato (`users`, in verde) per stato occupazionale, stato sentimentale e presenza di figli. 5

1.3 Profilo generale delle variabili di stile di vita nella coorte dei 146.258 minorenni: distribuzione della qualità della dieta (`diet_quality`, analizzata nel Capitolo 2), delle ore di sonno per notte e del tempo attivo su Instagram per singolo anno di età (approfondito nel Capitolo 3). 7

2.1 Distribuzione di diet_quality prima di applicare le tecniche di sampling . . . 10

2.2 Distribuzione di diet_quality dopo il sampling 11

2.3 Matrice di correlazione dopo le operazioni di sampling 11

3.1 Distribuzioni univariate con curva di densità KDE, media e mediana per le principali feature comportamentali e psicologiche ($N = 146.258$ minorenni). . 20

3.2 Analisi bivariata: esposizione giornaliera a Instagram contro Stress Percepito ($r = +0,850$), Felicità Dichiarata ($r = -0,385$) e distribuzione per fascia clinica di stress. 21

3.3 Matrice di correlazione di Pearson sulle 19 feature numeriche iniziali ($N =$ 146.258 minorenni). 22

3.4 A sinistra: matrice di correlazione post-scrematura sulle 7 Feature Core. A destra: stile di navigazione (Sessioni/Giorno contro Durata Media Sessione, colorato per punteggio di Stress). 23

3.5 A sinistra: varianza spiegata singola e cumulativa dalla PCA. A destra: Heatmap di Comunalità (% di varianza preservata per ciascuna feature al variare di $k = 1 \dots 7$). 24

3.6 Heatmap della Matrice dei Pesi (*Loadings*) delle 5 Componenti Principali ottime (`PC1`–`PC5`). 25

3.7 Selezione del numero ottimo di cluster k per K-Means: Metodo del Gomito (WCSS), Riduzione marginale % della WCSS e andamento del Silhouette Score ($k = 2 \dots 8$). 26

3.8 Visualizzazione geometrica dei 3 cluster K-Means: proiezione 2D PCA, 3D PCA e iperpiano discriminante 2D LDA. 27
3.9 Profilazione semantica dei 3 Cluster K-Means ($N = 146.258$ minorenni): distribuzione percentuale, Heatmap Z-Score dei centroidi e Radar Chart dei percentili. 27
3.10 A sinistra: distribuzione dei Silhouette Score per cluster ($k = 3$). A destra: allineamento percentuale tra i cluster non supervisionati e le 3 classi di Rischio Stress (Opzione A1). 28
3.11 DBSCAN: curva k-Distance (a sinistra), Heatmap del Silhouette Score sui cluster validi (al centro) e Heatmap del numero di cluster e percentuale di Outlier `-1` (a destra). 29
3.12 DBSCAN ($\varepsilon = 0,60$, min_samples $= 10$): proiezione 2D PCA, 3D PCA e caratterizzazione degli Outlier (`-1`) tramite distribuzione di `posts_created_per_week`. 29
3.13 HDBSCAN: estrazione macro-stabile `EOM` in 2D PCA (a sinistra), grado di certezza/probabilità in 3D PCA (al centro) ed estrazione dei 3 nuclei archetipici puri tramite metodo `Leaf` (a destra). 30

Elenco delle tabelle

1.1 Catalogo delle feature — Parte I: Area Demografica e Socio-Economica (13 variabili), Salute Fisica e Stile di Vita (10 variabili), Benessere Psicologico (2 variabili). 3
1.2 Catalogo delle feature — Parte II: Volumi di Attività e Interazione su Instagram (13 variabili), Ripartizione del Tempo sull'App (7 variabili), Profilo Account, Preferenze e Metadati (13 variabili). 4
1.3 Riepilogo delle 6 colonne sottoposte a correzione di integrità semantica tra `instagram_usage_lifestyle.csv` (Raw) e `instagram_users_lifestyle.csv` (Cleaned). 6

2.1 Confronto delle performance dei modelli base: accuratezza media calcolata sul test set 13
2.2 Confronto delle performance dei modelli a seguito dell'ottimizzazione tramite Grid Search 13
2.3 Requisiti dell'acqua estratta per gli impianti open loop [UNI EN 15450, 2008] 15

3.1 Statistiche descrittive delle 19 feature numeriche iniziali ($N = 146.258$ minorenni, 13–17 anni). 19
3.2 Prime 15 coppie di variabili con correlazione lineare fortissima ($|r| > 0,80$) su un totale di 59 coppie collineari individuate (34,50% delle 171 coppie totali). . 22
3.3 Tabella di Comunalità: percentuale di varianza di ogni singola feature preservata al variare del numero di componenti principali k mantenute. 24
3.4 Matrice dei Pesi (*Loadings*) delle prime 5 Componenti Principali. 25
3.5 Metriche quantitative di valutazione per K-Means al variare di $k \in \{2, \dots, 8\}$. 26
3.6 Profilazione completa dei 3 Cluster individuati da K-Means nei valori medi reali originali ($N = 146.258$ minorenni). 27
3.7 Approfondimento K-Means con $k = 4$: scissione del gruppo ad Alto Rischio nei due fenotipi *Maratoneti Immersivi* (Cl.2) e *Compulsivi FOMO* (Cl.3). 28
3.8 Profilazione dei Cluster e degli Outlier (`-1`) individuati da DBSCAN ($\varepsilon = 0,60$, min_samples $= 10$, $N = 20.000$). 29
3.9 Profilazione di HDBSCAN con metodo `EOM` (`min_cluster_size=100, min_samples=15`, Silhouette $= 0,6061$) e metodo `Leaf` (`min_cluster_size=200, min_samples=10`, Silhouette $= 0,4512$). 30
3.10 Tabella riassuntiva di confronto finale tra i 3 algoritmi di Clustering analizzati. 31

4.1 Requisiti dell'acqua estratta per gli impianti open loop [UNI EN 15450, 2008] 35

CAPITOLO 1

Analisi descrittiva del dataset

1.1 Panoramica Generale e Obiettivi dello Studio

Il presente elaborato si propone di analizzare in modo rigoroso e multidisciplinare la relazione tra le abitudini di utilizzo dei social media — con particolare riferimento alla piattaforma **Instagram** — lo stile di vita quotidiano e gli indicatori di benessere psicofisico. Lo studio prende in esame un vasto patrimonio informativo composto originariamente da 1.547.896 **profili utente** descritti attraverso 58 **attributi** eterogenei (variabili numeriche continue, conteggi discreti, variabili categoriche nominali/ordinali e indicatori booleani).

L'architettura complessiva del documento è strutturata in tre fasi sequenziali e complementari:

1. **Capitolo 1 — Analisi Descrittiva del Dataset:** esamina la struttura globale dei dati ($N = 1.547.896$), cataloga le 58 feature per dominio semantico, documenta il processo di *Data Quality & Cleaning* (confrontando la versione grezza `instagram_usage_lifestyle.csv` con la versione validata `instagram_users_lifestyle.csv`) e definisce il perimetro sperimentale focalizzato sulla popolazione dei **minorenni di età compresa tra** 13 **e** 17 **anni (**$N = 146.258$**)**.

2. **Capitolo 2 — Analisi di Classificazione (Apprendimento Supervisionato):** sviluppa e ottimizza modelli predittivi sulla coorte dei minorenni, affrontando il bilanciamento delle classi tramite tecniche combinate di *oversampling* (*SMOTE*) e *undersampling* (*ClusterCentroids*), la ricerca degli iperparametri ottimi (*Grid Search*) e metodi di *Ensemble Learning*.

3. **Capitolo 3 — Analisi di Clustering ed Esplorazione Approfondita (Apprendimento Non Supervisionato):** approfondisce l'Analisi Esplorativa dei Dati (*EDA*) sulle metriche comportamentali e psicologiche dei minorenni, applica la selezione delle feature tramite studio della multicollinearità ($|r| > 0,80$), riduce la dimensionalità con una **PCA a distorsione zero (**$k = 5$ **componenti)** e confronta tre algoritmi di clustering (**K-Means**, **DBSCAN** e **HDBSCAN**) per individuare i profili di rischio per la salute mentale (*User Personas*) e gli *Outlier* comportamentali.

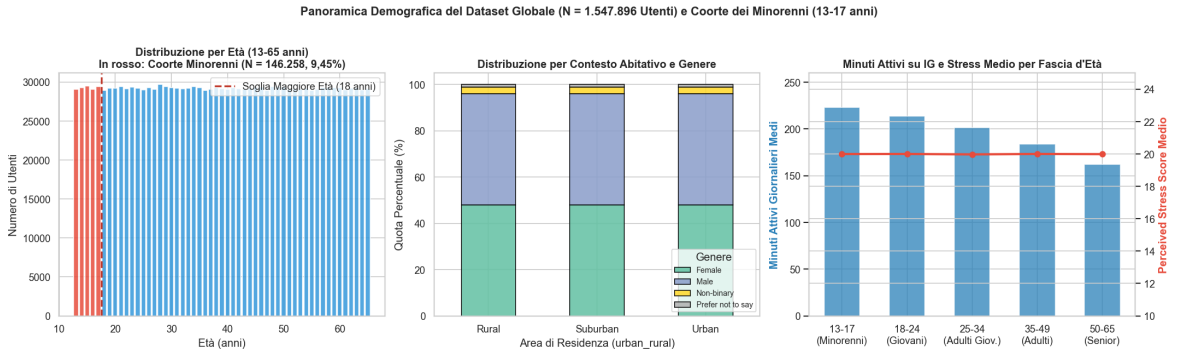


Figura 1.1: Panoramica demografica dell'intero dataset ($N = 1.547.896$ utenti, 13–65 anni): distribuzione per età con isolamento della coorte dei minorenni ($N = 146.258, 9, 45\%$), ripartizione per contesto abitativo e genere, e andamento del tempo attivo medio su Instagram e dello stress percepito per fascia d'età.

Come evidenziato nella Figura 1.1, la distribuzione per età copre uniformemente lo spettro compreso tra i 13 e i 65 anni (con una media globale di $38,99$ anni). Tuttavia, il pannello di destra rivela immediatamente il motivo scientifico per cui i capitoli di modellazione si concentrano sulla fascia **13–17 anni**: gli adolescenti minorenni registrano il **più alto tempo medio di esposizione giornaliera a Instagram (**$223,21$ **minuti/giorno, ovvero oltre** 3 **ore e** 43 **minuti)** abbinato al **più elevato punteggio medio di stress percepito (**$19,99/40$**)** rispetto a tutte le fasce d'età adulte.

1.2 Catalogo Completo delle 58 Feature e Tipologia dei Dati

Il dataset originale presenta 1.547.896 **righe e** 58 **colonne**, senza alcun valore mancante (`NaN = 0` su tutte le colonne). Dal punto di vista della rappresentazione informatica, i 58 attributi si suddividono in:

- **31 variabili intere (`int64`):** identificativi, età, conteggi giornalieri/settimanali di interazioni (like, commenti, Reels, Stories, DM), minuti spesi nelle singole sezioni dell'app e punteggi psicologici discreti;
- **7 variabili reali in virgola mobile (`float64`):** ore lavorative settimanali, ore di sonno per notte, ore di esercizio fisico, indice di massa corporea (`body_mass_index`), durata media delle sessioni e punteggio composito di coinvolgimento (`user_engagement_score`);
- **19 variabili testuali/categoriche (`object`):** attributi socio-demografici, abitudini alimentari e di stile di vita, preferenze sui contenuti e data di ultimo accesso (`last_login_date`);
- **1 variabile booleana (`bool`):** indicatore di sottoscrizione a funzionalità premium (`uses_premium_features`).

Per facilitare la comprensione del dominio applicativo, le 58 variabili sono state classificate in **7 macro-aree tematiche**, riportate integralmente nelle Tabelle 1.1 e 1.2.

Tabella 1.1: Catalogo delle feature — Parte I: Area Demografica e Socio-Economica (13 variabili), Salute Fisica e Stile di Vita (10 variabili), Benessere Psicologico (2 variabili).

Area Tematica	Nome Attributo	Tipo e Dominio / Range	Descrizione Semantica
1. Demografia	`user_id`	`int64` (1 . . . 1.547.896)	Identificativo numerico univoco dell'utente (chiave primaria).
e Contesto	`age`	`int64` (13 . . . 65 anni)	Età anagrafica dell'utente (media globale: 38,99 anni).
Socio-Econ.	`gender`	`object` (4 categorie)	Genere (*Female* 48%, *Male* 48%, *Non-binary* 3%, *Prefer not to say* 1%).
(13 feature)	`country`	`object` (10 categorie)	Paese di residenza (*USA, India, Brazil, UK, Canada, Japan, Germany, Australia, South Korea, Other*).
	`urban_rural`	`object` (3 categorie)	Contesto abitativo (*Urban* 55%, *Suburban* 30%, *Rural* 15%).
	`income_level`	`object` (5 classi ordinali)	Fascia di reddito (*Low, Lower-middle, Middle, Upper-middle, High*).
	`employment_status`	`object` (6 categorie)	Stato occupazionale (*Full-time, Student, Part-time, Self-employed, Unemployed, Retired*).
	`education_level`	`object` (6 classi ordinali)	Titolo di studio (*High school, Bachelor's, Master's, Some college, Doctorate, Other*).
	`relationship_status`	`object` (5 categorie)	Stato civile/affettivo (*Single, Married, In a relationship, Divorced, Widowed*).
	`has_children`	`object` (*Yes / No*)	Presenza di figli a carico.
	`weekly_work_hours`	`float64` (0,0 . . . 80,0 h)	Ore settimanali dedicate al lavoro retribuito.
	`hobbies_count`	`int64` (0 . . . 10)	Numero di hobby extracurriculari o passatempi praticati.
	`social_events_per_month`	`int64` (0 . . . 15)	Partecipazione mensile a eventi sociali dal vivo (offline).
2. Salute Fisica	`sleep_hours_per_night`	`float64` (3,0 . . . 10,0 h)	Ore medie di sonno per notte (media globale: 6,99 h).
e Abitudini	`exercise_hours_per_week`	`float64` (0,0 . . . 20,0 h)	Ore settimanali dedicate all'attività fisica o sportiva.
Quotidiane	`diet_quality`	`object` (5 classi ordinali)	Qualità dell'alimentazione (*Very poor, Poor, Average, Good, Excellent*).
(10 feature)	`smoking`	`object` (3 categorie)	Abitudine al fumo (*Never, Former, Current*).
	`alcohol_frequency`	`object` (5 categorie)	Frequenza consumo alcolici (*Never, Rarely, Weekly, Several times a week, Daily*).
	`body_mass_index`	`float64` (15,0 . . . 45,0)	Indice di Massa Corporea (BMI).
	`blood_pressure_systolic`	`int64` (90 . . . 180 mmHg)	Pressione arteriosa sistolica (massima).
	`blood_pressure_diastolic`	`int64` (60 . . . 120 mmHg)	Pressione arteriosa diastolica (minima).
	`daily_steps_count`	`int64` (1.000 . . . 20.000)	Conteggio medio giornaliero dei passi effettuati.
	`books_read_per_year`	`int64` (0 . . . 30)	Numero di libri letti in un anno.
3. Benessere	`perceived_stress_score`	`int64` (0 . . . 40)	Punteggio clinico di stress percepito (scala PSS a 40 punti).
Psicologico	`self_reported_happiness`	`int64` (1 . . . 10)	Livello di felicità e soddisfazione vitale auto-dichiarata.

Tabella 1.2: Catalogo delle feature — Parte II: Volumi di Attività e Interazione su Instagram (13 variabili), Ripartizione del Tempo sull'App (7 variabili), Profilo Account, Preferenze e Metadati (13 variabili).

Area Tematica	Nome Attributo	Tipo e Dominio / Range	Descrizione Semantica
4. Volumi di	`daily_active_minutes_instagram`	`int64` (5 . . . 590 min/dì)	Tempo totale giornaliero trascorso attivamente su Instagram.
Attività e	`sessions_per_day`	`int64` (1 . . . 50 sessioni)	Numero di accessi giornalieri distinti all'applicazione.
Interazioni IG	`average_session_length_minutes`	`float64` (5,0 . . . 50,0 min)	Durata media in minuti di ciascuna sessione di navigazione.
(13 feature)	`reels_watched_per_day`	`int64` (18 . . . 300)	Numero di video brevi (*Reels*) visualizzati al giorno.
	`stories_viewed_per_day`	`int64` (10 . . . 150)	Numero di *Stories* visualizzate quotidianamente.
	`likes_given_per_day`	`int64` (8 . . . 350)	Numero di "Mi piace" assegnati ai contenuti ogni giorno.
	`comments_written_per_day`	`int64` (0 . . . 80)	Numero di commenti scritti giornalmente.
	`posts_created_per_week`	`int64` (0 . . . 30)	Numero di post pubblicati sul proprio profilo a settimana.
	`dms_sent_per_week`	`int64` (0 . . . 97)	Messaggi diretti (*DM*) inviati settimanalmente.
	`dms_received_per_week`	`int64` (0 . . . 111)	Messaggi diretti (*DM*) ricevuti settimanalmente.
	`ads_viewed_per_day`	`int64` (0 . . . 62)	Annunci pubblicitari sponsorizzati visualizzati al giorno.
	`ads_clicked_per_day`	`int64` (0 . . . 20)	Click effettuati sugli annunci pubblicitari giornalieri.
	`user_engagement_score`	`float64` (0,67 . . . 15,80)	Indice sintetico di qualità e intensità dell'engagement.
5. Ripartizione	`time_on_feed_per_day`	`int64` (2 . . . 328 min)	Minuti giornalieri trascorsi scorrendo il *Feed* principale.
del Tempo e	`time_on_explore_per_day`	`int64` (1 . . . 171 min)	Minuti giornalieri trascorsi nella sezione *Esplora*.
Abitudini	`time_on_messages_per_day`	`int64` (1 . . . 138 min)	Minuti giornalieri dedicati alla messaggistica diretta (*DM*).
Connesse	`time_on_reels_per_day`	`int64` (2 . . . 227 min)	Minuti giornalieri dedicati alla visione di *Reels*.
(7 feature)	`notification_response_rate`	`float64` (0,0 . . . 1,0)	Tasso di risposta immediata alle notifiche push ricevute.
	`volunteer_hours_per_month`	`float64` (0,0 . . . 30,0 h)	Ore mensili dedicate ad attività di volontariato.
	`travel_frequency_per_year`	`int64` (0 . . . 15)	Numero di viaggi effettuati in un anno.
6. Metriche	`followers_count`	`int64` (10 . . . 500.000+)	Numero totale di follower dell'account.
Account,	`following_count`	`int64` (10 . . . 10.000)	Numero di profili seguiti dall'utente.
Preferenze e	`account_creation_year`	`int64` (2010 . . . 2025)	Anno di creazione del profilo Instagram.
Metadati	`last_login_date`	`object` (Data ISO)	Data dell'ultimo accesso effettuato (`YYYY-MM-DD`).
(13 feature)	`content_type_preference`	`object` (6 categorie)	Formato preferito (*Reels*, *Stories*, *Photos*, *Carousels*, *Live*, *Mixed*).
	`preferred_content_theme`	`object` (8 categorie)	Tema preferito (*Fitness*, *Tech*, *Fashion*, *Food*, *Travel*, *Art*, *Music*, *Other*).
	`privacy_setting_level`	`object` (3 categorie)	Impostazione privacy del profilo (*Public*, *Friends only*, *Private*).
	`two_factor_auth_enabled`	`object` (*Yes* / *No*)	Attivazione dell'autenticazione a due fattori (2FA).
	`biometric_login_used`	`object` (*Yes* / *No*)	Utilizzo di accesso biometrico (impronta/FaceID).
	`linked_accounts_count`	`int64` (0 . . . 5)	Numero di altri profili social collegati all'account.
	`subscription_status`	`object` (3 categorie)	Piano di abbonamento (*Free*, *Premium*, *Business*).
	`uses_premium_features`	`bool` (*True* / *False*)	Utilizzo effettivo di funzionalità avanzate/premium.
	`app_name`	`object` (Costante)	Nome dell'applicazione monitorata (sempre "*Instagram*").

1.3 Analisi di Data Quality: Confronto tra Dataset Grezzo (usage) e Validato (users)

Un passaggio metodologico cruciale prima di qualunque attività di modellazione è consistito nella verifica puntuale delle due versioni disponibili del dataset globale:

1. `instagram_usage_lifestyle.csv` (*Versione Grezza / Raw*, 1.547.896 × 58);
2. `instagram_users_lifestyle.csv` (*Versione Pulita e Validata / Cleaned*, 1.547.896 × 58).

Attraverso un confronto cella-per-cella sull'intera matrice di 89,77 milioni di valori, è stato dimostrato che **52 colonne su 58 sono identiche al 100%** tra i due file, mentre le restanti **6 colonne socio-anagrafiche** presentavano nella versione grezza (`usage`) gravi incoerenze logiche dovute a generazione casuale non vincolata sull'età dei soggetti più giovani (minorenni 13–17 anni e giovani adulti 18–25 anni), che sono state interamente sanate nella versione validata (`users`).

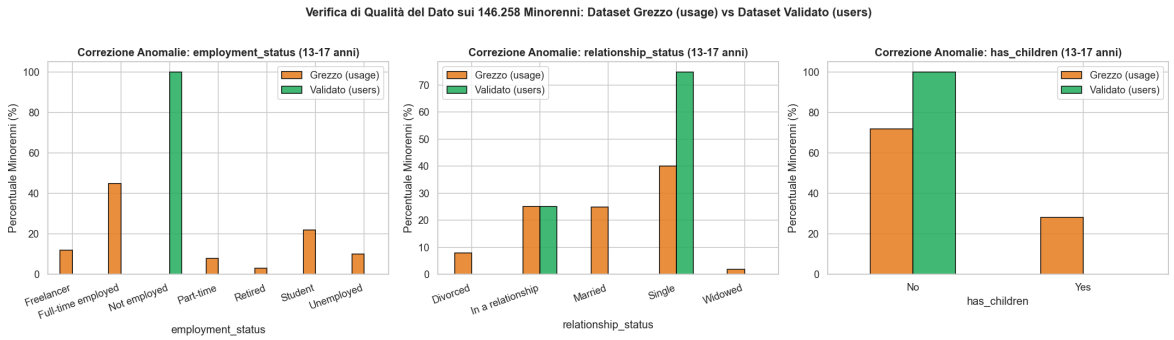


Figura 1.2: Impatto della validazione dei dati sui 146.258 minorenni (13–17 anni): confronto tra il file grezzo (`usage`, in arancione) e il file validato (`users`, in verde) per stato occupazionale, stato sentimentale e presenza di figli.

Tabella 1.3: Riepilogo delle 6 colonne sottoposte a correzione di integrità semantica tra `instagram_usage_lifestyle.csv` (Raw) e `instagram_users_lifestyle.csv` (Cleaned).

Attributo	Righe Corrette	% Sul Totale	Anomalia nel File Grezzo (`usage`)	Regola di Validazione nel File Pulito (`users`)
`employment_status`	218.210	14,10%	Minorenni di 13–17 anni classificati come *Full-time employed* (44,9%), *Retired* (pensionati, 4,9%) o *Self-employed*.	Tutti i minorenni (age $<$ 18) impostati a `Not employed`; giovani 18–22 anni riallineati prevalentemente a `Student`.
`weekly_work_hours`	142.345	9,20%	Ragazzi di 13–17 anni con orari lavorativi fino a 40–60 ore/settimana (media 16,56 h).	Ore lavorative azzerate (0,0 h/settimana) per il 100% dei soggetti di età inferiore a 18 anni.
`relationship_status`	98.069	6,34%	Adolescenti di 13–17 anni registrati come *Married* (25,0%), *Divorced* (6,9%) o *Widowed* (2,9%).	Rimossi stati civili incompatibili con la minore età; ammessi solo `Single` (76,9%) e `In a relationship` (23,1%).
`has_children`	65.941	4,26%	Oltre il 29,8% dei minorenni (13–17 anni) risultava avere figli a carico (`Yes`).	Impostato rigorosamente a `No` per il 100% dei minorenni (146.258 su 146.258).
`education_level`	53.300	3,44%	Minorenni o diciottenni già in possesso di *Master's* (Laurea Magistrale) o *Doctorate* (Dottorato).	Titolo di studio vincolato all'età scolare effettiva (`High school` / `Other` per i minorenni).
`account_creation_year`	32.266	2,08%	Utenti di 13–15 anni con account creato nel 2010 (quando non erano ancora nati o avevano 1 anno).	Anno di creazione dell'account vincolato a un'età minima plausibile dell'utente.

1.4 Definizione del Perimetro sui Minorenni ($N = 146.258$) e Preparazione del Dataset

Alla luce delle evidenze emerse, tutte le analisi dei capitoli successivi sono state condotte a partire esclusivamente dal file validato `instagram_users_lifestyle.csv`, applicando il filtro demografico `age` $<$ 18 tramite script Python (evitando l'uso di fogli elettronici tradizionali come Microsoft Excel che, avendo un limite strutturale di 1.048.576 righe, avrebbero troncato oltre un terzo del dataset originale perdendo 47.240 minorenni).

L'estrazione completa restituisce esattamente 146.258 **utenti minorenni** (13–17 anni). Su questo sottoinsieme è stata operata una pulizia strutturale delle colonne, passando da 58 a 45 **feature utili** (`dataset_minorenni_pulito.csv`) mediante la rimozione di:

- **10 attributi amministrativi o non informativi:** `user_id` (codice seriale), `app_name` (costante "*Instagram*"), `last_login_date`, `subscription_status`, `uses_premium_features`, `content_type_preference`, `preferred_content_theme`, `privacy_setting_level`, `income_level`, `education_level`;
- **3 attributi divenuti a varianza zero (costanti) sul perimetro dei minorenni validati:** `employment_status` (100% *Not employed*), `weekly_work_hours` (100% pari a 0,0) e `has_children` (100% *No*).

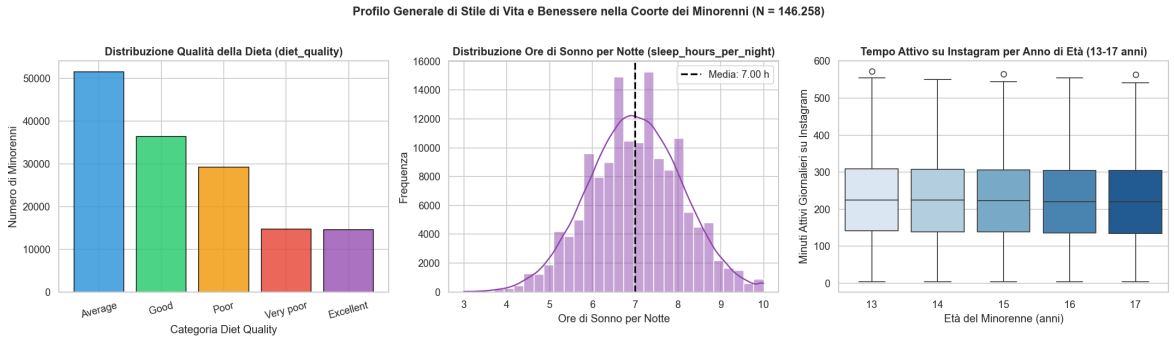


Figura 1.3: Profilo generale delle variabili di stile di vita nella coorte dei 146.258 minorenni: distribuzione della qualità della dieta (`diet_quality`, analizzata nel Capitolo 2), delle ore di sonno per notte e del tempo attivo su Instagram per singolo anno di età (approfondito nel Capitolo 3).

La Figura 1.3 illustra infine il ponte logico verso i due capitoli di modellazione che seguono:

- Nel **Capitolo 2 (Classificazione)** viene affrontato il problema predittivo supervisionato legato alle abitudini di stile di vita e alla qualità nutrizionale (`diet_quality`) dei minorenni, mostrando come lo sbilanciamento delle classi (visibile nel primo pannello di Figura 1.3) richieda tecniche mirate di ricampionamento e come la natura multifattoriale del dato incida sull'accuratezza dei classificatori.

- Nel **Capitolo 3 (Clustering)** viene sviluppata l'analisi esplorativa e non supervisionata sul legame fortissimo tra l'esposizione a Instagram e il rischio per la salute mentale (`perceived_stress_score` e `self_reported_happiness`), dimostrando come gli algoritmi **K-Means**, **DBSCAN** e **HDBSCAN** riescano a segmentare i 146.258 adolescenti in profili di rischio clinicamente e comportamentalmente ben definiti.

CAPITOLO 2

Minors' Lifestyle Analysis: classificazione

La classificazione è stata condotta con l'obiettivo di sviluppare modelli predittivi in grado di stimare la qualità della dieta dei minorenni sulla base delle loro abitudini di vita e degli altri attributi presenti nel dataset. Il processo ha incluso un'analisi esplorativa approfondita, la gestione dello sbilanciamento delle classi tramite campionamento, l'applicazioni di diversi algoritmi di machine learning (ottimizzati tramite Grid Search) e, infine, l'integrazione di tecniche di Ensemble Learning per tentare di migliorare ulteriormente le prestazioni e la robustezza della classificazione.

2.1 Selezione delle feature e pulizia del dataset

Prima di procedere con le fasi di addestramento e ottimizzazione dei modelli, è stata effettuata un'attenta analisi preliminare degli attributi presenti nel dataset, che ha portato all'eliminazione di un sottoinsieme di colonne non rilevanti o potenzialmente distorsive per il task predittivo:

- **`user_id`**: Identificativo univoco dell'utente; trattandosi di un codice seriale privo di valore numerico o semantico, la sua inclusione avrebbe introdotto un rumore casuale non generalizzabile.
- **`app_name`**: Nome dell'applicazione, caratterizzato da un valore costante o non informativo ai fini della predizione comportamentale della dieta.
- **`education_level`**: Livello di istruzione, escluso in quanto non correlato o non significativo per il target demografico dei minorenni considerato nel perimetro d'analisi.
- **`last_login_date`**: Timestamp relativo all'ultimo accesso, variabile temporale priva di utilità predittiva diretta per la valutazione della qualità della dieta.
- **`subscription_status`** e **`uses_premium_features`**: Attributi di natura commerciale e amministrativa legati all'account dell'utente, totalmente slegati dalle abitudini alimentari e dallo stile di vita.
- **`content_type_preference`** e **`preferred_content_theme`**: Preferenze sui contenuti multimediali fruiti, ritenute troppo frammentate e prive di una correlazione diretta con il comportamento nutrizionale.

- **`privacy_setting_level`**: Livello di impostazione della privacy, variabile amministrativa irrilevante per la modellazione del target nutrizionale.
- **`income_level`**: Livello di reddito, escluso per evitare distorsioni o stime non attendibili, trattandosi di un campione focalizzato sui minorenni dove tale dato risulta spesso stimato o non direttamente incidente sulle abitudini quotidiane rilevate.
- **`perceived_stress_score`**: Punteggio di stress percepito, rimosso in quanto presentava criticità di coerenza o valori non uniformi all'interno della distribuzione complessiva del campione.

L'esclusione di queste variabili ha permesso di alleggerire la dimensionalità dello spazio delle feature, focalizzando l'attenzione esclusivamente sugli attributi comportamentali e sullo stile di vita realmente incidenti sul benessere dei soggetti.

2.2 Preprocessing del dataset

Per affrontare il problema dello sbilanciamento delle classi nella variabile target *diet_quality* (vedi Figura 2.1), è stata adottata una combinazione di tecniche di oversampling e undersampling. L'obiettivo era riequilibrare la distribuzione dei campioni per ciascuna classe, fissando il target a 20.000 elementi per categoria, data l'ampia numerosità complessiva del dataset. Questa procedura è stata applicata esclusivamente al dataset di training, preservando il dataset di test per una valutazione finale non influenzata.

2.2.1 Bilanciamento del dataset

Per aumentare il numero di campioni delle classi minoritarie della variabile target *diet_quality*, è stata utilizzata la tecnica *SMOTE* (Synthetic Minority Over-sampling Technique). Questa tecnica genera nuovi campioni sintetici interpolando tra i campioni esistenti, mantenendo inalterata la distribuzione delle feature. L'intervento è stato combinato con tecniche di sottocampionamento sulla classe maggioritaria per riportare ciascuna categoria a una numerosità bilanciata di riferimento, applicando il processo esclusivamente sul dataset di training per preservare l'integrità del test set.

Per ridurre il numero di campioni delle classi maggioritarie della variabile target *diet_quality* fino a raggiungere la soglia di bilanciamento stabilita, è stata utilizzata la tecnica di *undersampling* basata sulla clusterizzazione (*ClusterCentroids*). Questo metodo identifica i cluster rappresentativi dei dati originali e seleziona i campioni centrali di ciascun cluster, mantenendo intatta la distribuzione delle feature.

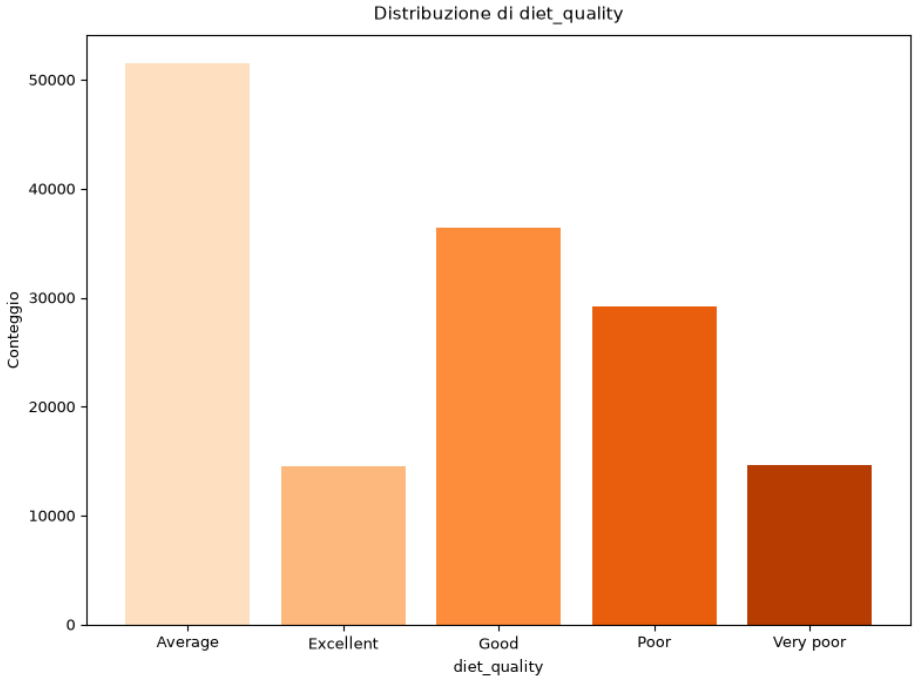


Figura 2.1: Distribuzione di diet_quality prima di applicare le tecniche di sampling

2.2.2 Dataset Finale

Dopo l'applicazione di entrambe le tecniche, il dataset di training bilanciato presenta esattamente 20.000 campioni per ciascuna classe della variabile target *diet_quality*. Questo dataset è stato salvato in un file CSV per l'addestramento dei modelli, insieme al dataset di test non bilanciato. In Figura 2.2 è possibile vedere il risultato della distribuzione dei campioni dopo il processo di bilanciamento.

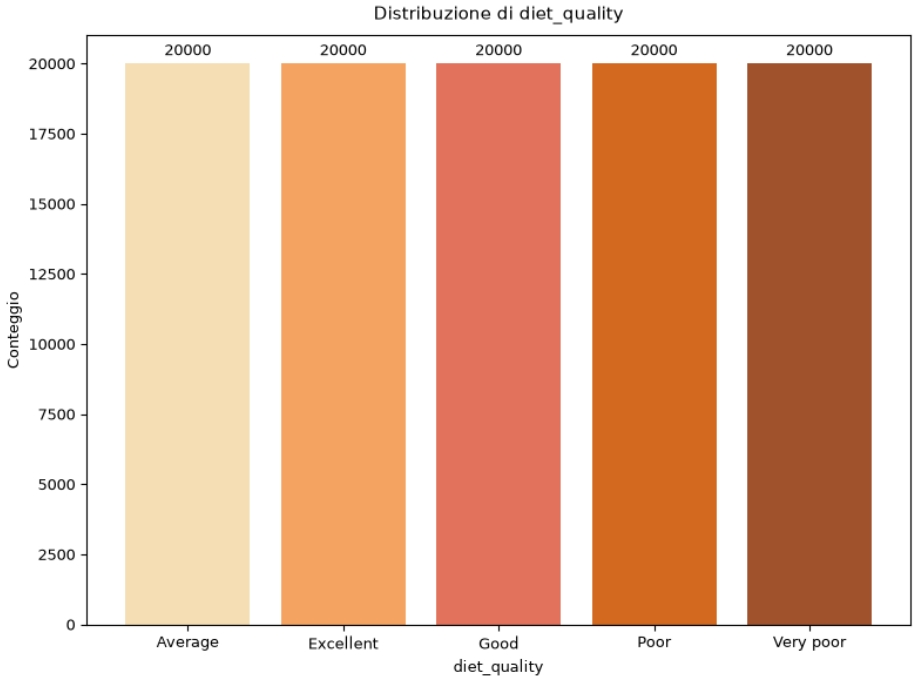


Figura 2.2: Distribuzione di diet_quality dopo il sampling

2.2.3 Analisi della distribuzione degli attributi

Al termine delle operazioni di oversampling e undersampling, è stata verificata la coerenza della distribuzione degli attributi nel dataset bilanciato. Per questo scopo è stata calcolata e visualizzata la matrice di correlazione delle feature. La matrice di correlazione fornisce una rappresentazione delle relazioni lineari tra le variabili, evidenziando eventuali cambiamenti nella struttura dei dati causati dalle operazioni di bilanciamento. In Figura 2.3 è possibile vedere la matrice ottenuta dopo le operazioni di sampling.

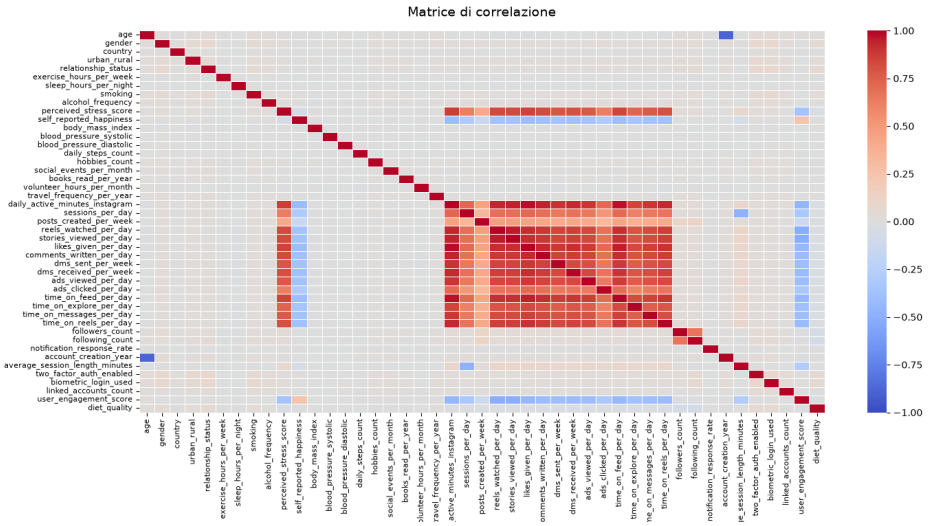


Figura 2.3: Matrice di correlazione dopo le operazioni di sampling

L'analisi della matrice di correlazione ha confermato che la distribuzione degli attributi nel dataset bilanciato è rimasta coerente con quella originale. Non sono emerse correlazioni

spuriamente elevate o relazioni alterate, a conferma che il bilanciamento delle classi non ha compromesso l'integrità del dataset.

2.3 Scenari di Classificazione

Nel procedere con la classificazione della variabile target *diet_quality*, l'impostazione degli scenari predittivi è stata guidata dai risultati emersi dall'analisi esplorativa e dalla matrice di correlazione. Al fine di valutare l'impatto degli attributi sul modello e impostare correttamente il task, sono state fatte le seguenti considerazioni metodologiche:

1. **Assenza di attributi derivati (Data Leakage)**: A differenza di altri contesti di studio (in cui figurano attributi continui da cui deriva direttamente e matematicamente la classe target), nel nostro dataset non sono presenti variabili che anticipino deterministicamente la *diet_quality*. Di conseguenza, non è stato necessario escludere a priori alcuna feature per rischio di *bias* o ridondanza informativa. Rimuovere ulteriori variabili in questa fase avrebbe compromesso l'integrità dell'analisi, impedendo ai modelli di apprendere dai reali pattern comportamentali.

2. **Inclusione totale delle feature comportamentali**: Dall'analisi della matrice di correlazione (Figura 2.3), nessuna variabile è risultata singolarmente ed eccezionalmente correlata con la variabile target. Per questo motivo, si è scelto di non frammentare l'addestramento in scenari multipli per esclusione (es. rimuovendo attributi dominanti per valutarne l'assenza), ma di configurare un **unico scenario di classificazione completo**. L'obiettivo di questo approccio è fornire in input agli algoritmi l'intero spettro delle variabili (quali ore di sonno, attività fisica, uso dei social) per permettere ai modelli di tentare di individuare relazioni non lineari latenti e sinergie complesse tra gli attributi.

2.4 Processo di Classificazione

Il processo di classificazione è stato applicato allo scenario completo precedentemente descritto, seguendo un approccio strutturato per garantire una valutazione oggettiva. I passi principali hanno incluso l'addestramento dei modelli base, la successiva ottimizzazione dei parametri e l'integrazione finale attraverso tecniche di ensemble learning. Gli algoritmi di machine learning selezionati per la classificazione della qualità della dieta sono:

- **Random Forest**
- **K-Nearest Neighbors**
- **Decision Tree**
- **Naive Bayes**
- **AdaBoost Classifier**
- **Gradient Boosting Classifier**

Si è proceduto in prima istanza addestrando i modelli con i parametri di default, al fine di stabilire una *baseline* prestazionale per valutare i successivi miglioramenti derivanti da approcci più sofisticati. I modelli sono stati addestrati sul dataset bilanciato e testati sul test set originale. I risultati preliminari, espressi in termini di accuratezza media (*Mean Accuracy*), sono riportati di seguito:

Index	Model	Mean Accuracy
0	Random Forest	0.1967
1	K-Nearest Neighbors	0.2158
2	Decision Tree	0.1893
3	Naive Bayes	0.1707
4	AdaBoost Classifier	0.2154
5	Gradient Boosting Classifier	0.2105

Tabella 2.1: Confronto delle performance dei modelli base: accuratezza media calcolata sul test set

Come si evince dai risultati in Tabella 2.1, le prestazioni iniziali si attestano mediamente intorno al 20%. Questo valore, pur apparendo esiguo, è coerente con la complessità intrinseca del dataset e conferma le difficoltà predittive già anticipate dall'analisi esplorativa della matrice di correlazione.

2.4.1 Ottimizzazione dei Modelli

Al fine di migliorare le prestazioni ottenute con le configurazioni di base, è stata applicata la tecnica della *Grid Search* combinata con una *5-fold cross-validation*. Questo approccio ha permesso di testare diverse combinazioni di iperparametri per individuare la configurazione ottimale per i modelli ritenuti più promettenti, ovvero Random Forest e K-Nearest Neighbors.

Per garantire l'efficienza computazionale su un dataset di grandi dimensioni, la ricerca degli iperparametri è stata condotta su un campione stratificato del training set bilanciato. I modelli ottimizzati sono stati successivamente riaddestrati sull'intero set di addestramento e valutati sul test set originale. I risultati post-ottimizzazione sono riportati nella Tabella 2.2.

Index	Model	Ottimizzato Mean Accuracy
0	Random Forest	0.2011
1	K-Nearest Neighbors	0.1875

Tabella 2.2: Confronto delle performance dei modelli a seguito dell'ottimizzazione tramite Grid Search

Come si può osservare, l'ottimizzazione degli iperparametri ha prodotto lievi variazioni prestazionali ma non ha portato a un incremento sostanziale dell'accuratezza, confermando la rigidità del task predittivo. Per tentare di superare questo limite strutturale, il passo metodologico successivo è consistito nell'applicazione di tecniche di Ensemble Learning.

2.5 Competenze del committente

Realizzare un sistema geotermico è attualmente oneroso e richiede una progettazione specialistica che pochi installatori possono assicurare o certificare. Il costo iniziale poi è più elevato degli impianti tradizionali e richiede la redazione di relazioni tecniche e idrogeologiche che interessano molteplici figure professionali, sia per il dimensionamento dell'impianto, sia per ottenere la concessione.

É bene esserne consapevoli e ricorrere a questo tipo di soluzione per impianti di una certa importanza e che possano servire più utenze. In questo modo si possono ridurre i costi ottimizzando le perforazioni e la gestione del sottosuolo e si possono prevedere analisi e progettazioni più dettagliate.

Inoltre un dimensionamento ottimale dei fabbisogni termici può contribuire a ridurre gli interventi sul terreno che rappresentano la parte più significativa del costo dell'impianto.

Vale la pena poi considerare nell'analisi costi/benefici, l'installazione di un sistema ibrido per coprire il carico di picco, se quest'ultimo si raggiunge per poche ore all'anno e far coprire al sistema geotermico il restante 90 % dell'energia termica richiesta.

Seguendo ed integrando quanto proposto da Rossi [2008], la committenza per ottenere l'autorizzazione alla realizzazione degli impianti geotermici, dovrà produrre una:

- domanda da presentare agli organi competenti;
- relazione idrogeologica preliminare;
- relazione idrogeologica finale.

Di seguito verranno schematizzati i contenuti base di queste domande e relazioni, suddividendole per tipo di impianto ed elencando le competenze della direzione lavori. Ovviamente gli enti di controllo richiederanno maggiori richieste, prescrizioni ed integrazioni a quanto sommariamente elencato. Qui si vuole solo fornire un quadro sintetico e generale, con evidenziate le richieste utili per richiedere ed agevolare l'autorizzazione.

2.6 Domanda e relazione tecnica preliminare

La domanda per i due sistemi comprenderà:

- dati anagrafici del richiedente;
- dati del progettista e della Direzione Lavori (se differente);
- dati indicativi della ditta e/o ditte (con eventuali certificazioni);
- dati significativi dell'impianto (perforazione e installazione);
- dati indicativi sull'ubicazione dell'impianto.

Dovranno poi essere allegati:

- relazione tecnica di progetto;
- corografia ubicativa 1:25 000 e planimetria catastale 1:2 000 ;

componenti	valore	unità di misura
materiale organico (possibilità di sedimentazione)	nessuna	-
valore di pH	$6,5 \div 9$	-
conduttività elettrica	$50 \div 1\,000$	$\mu\,\mathrm{S\,cm^{-1}}$
cloruro	< 300	$\mathrm{mg\,\ell^{-1}}$
ferro e manganese	< 1	$\mathrm{mg\,\ell^{-1}}$
solfato	< 2	$\mathrm{mg\,\ell^{-1}}$
contenuto di O_2	< 2	$\mathrm{mg\,\ell^{-1}}$
cloro	$0 \div 5$	$\mathrm{mg\,\ell^{-1}}$
nitrato	$0 \div 100$	$\mathrm{mg\,\ell^{-1}}$

Tabella 2.3: Requisiti dell'acqua estratta per gli impianti open loop [UNI EN 15450, 2008]

2.6.1 Per sistemi open loop

La relazione tecnica comprenderà:

▶ Dati tecnici

- potenza dell'impianto (kW_t);
- fabbisogno termico mensile, con carico medio e di picco;
- portata necessaria (m^3s^{-1});
- ΔT (K o ℃);
- dotazioni di sicurezza e controllo.

▶ Dati idrogeologici

- controllo dei vincoli esistenti nell'area di indagine;
- inquadramento geologico;
- idrogeologia del sottosuolo (caratteristiche dell'acquifero, permeabilità e direzione di flusso);
- censimento dei pozzi esistenti nell'area e di altre perforazioni:
- analisi qualitativa dell'acqua prelevata e restituita alla falda.

► Progetto

- schema di progetto per la costruzione dei pozzi, con particolare riferimento a diametri e materiali di filtri e rivestimento;
- descrizione sulle metodologie previste per eseguire a regola d'arte la cementazione del foro;
- valutazioni sulle possibili conseguenze relative al prelievo dell'acqua e sulla reimmissione, indicando il ΔT previsto a breve e a lungo termine (il massimo ammesso è di 5 °C) e la compatibilità ambientale dello scarico nel corpo recipiente.

2.6.2 Per sistemi closed loop

La relazione tecnica comprenderà:

► Dati tecnici

- potenza dell'impianto (kW_t);
- fabbisogno termico mensile, con carico medio e di picco;
- fluidi, additivi e anticongelanti che verranno utilizzati;
- ΔT (K o °C);
- dotazioni di sicurezza e controllo.

► Dati idrogeologici

- controllo dei vincoli esistenti nell'area di indagine;
- inquadramento geologico;
- idrogeologia del sottosuolo (caratteristiche dell'acquifero o degli acquiferi attraversati, permeabilità e direzione di flusso);
- censimento dei pozzi esistenti nell'area e di altre perforazioni.

► Progetto

- schema di progetto per la costruzione della sonda o del campo sonde;
- indicazioni specifiche sulla metodologia di perforazione e sui relativi diametri;
- descrizione sulle metodologie previste per eseguire a regola d'arte la cementazione del foro.
- simulazione degli effetti con definizione del tipo, della localizzazione e della quantità della perturbazione termica, a breve e a lungo termine.

2.6.3 Compiti della direzione lavori

Dovrà verificare la corretta esecuzione della posa in opera e controllare che in fase di perforazione la stratigrafia (i cui campioni dovranno essere lasciati a disposizione delle autorità competenti), sia corrispondente a quella prevista in fase di progetto ed in caso contrario predisporre delle adeguate soluzioni tecniche per mitigare le novità emerse.

Dovrà verificare con particolare attenzione gli aspetti relativi alla cementazione, dovendone certificare poi la tenuta. Inoltre eseguirà a seconda dell'impianto realizzato:

- prova di verifica a pressione della tenuta;
- prova di portata nel pozzo di presa e di immissione in quello di scarico.

2.7 Relazione tecnica finale

2.7.1 Per sistemi open loop

Comprenderà:

- dati stratigrafici effettivi;
- schema effettivo dei pozzi realizzati;
- dati idrogeologici derivanti anche dai risultati delle prove di pompaggio eseguite;
- valutazioni sulle possibili conseguenze del prelievo e della restituzione;
- calcolo dell'area influenzata dal ΔT nel breve e lungo termine (bulbo termico).

Verrà allegata:

- la planimetria con le effettive ubicazioni dei pozzi eseguiti con evidenziato il raggio di influenza del ΔT a breve e lungo termine.

La D.L. attesterà mediante dichiarazione sottoscritta la tenuta della cementazione, dell'impianto, la non interferenza tra le falde eventualmente presenti sia tra loro che con la superficie e la compatibilità ambientale dello scarico nel corpo recipiente.

2.7.2 Per sistemi closed loop

Comprenderà:

- dati stratigrafici effettivi;
- schema effettivo dei pozzi realizzati;
- variazioni rispetto al progetto preliminare;
- dati relativi alla cementazione eseguita;
- simulazione effettiva degli effetti con definizione del tipo, della localizzazione e della quantità della perturbazione termica, a breve e a lungo termine.

Verrà allegata:

- la planimetria con le effettive ubicazioni delle sonde eseguite e la perturbazione termica, a breve e a lungo termine.

La D.L. attesterà mediante dichiarazione sottoscritta la tenuta della cementazione e dell'impianto e la non interferenza tra le falde eventualmente presenti, sia tra loro che con la superficie.

CAPITOLO 3

Minors' Lifestyle Analysis: clustering

3.1 Introduzione e Obiettivo del Clustering

Nel presente capitolo viene sviluppata un'analisi di **Apprendimento Non Supervisionato (Clustering)** focalizzata sulla popolazione adolescenziale (**13–17 anni**, $N = 146.258$ utenti minorenni estratti dalla versione validata `instagram_users_lifestyle.csv`). L'obiettivo dell'analisi è duplice e si integra direttamente con l'analisi predittiva sul benessere e il rischio di salute mentale nei minorenni (*Opzione A1 — Rischio Salute Mentale negli Adolescenti*):

1. **Scoperta autonoma delle User Personas (Segmentazione Comportamentale e Psicologica):** verificare se, senza fornire all'algoritmo alcuna etichetta predefinita (*target*), i minorenni si raggruppano naturalmente in profili distinti per intensità di utilizzo di Instagram, stile di fruizione (sessioni lunghe contro accessi compulsivi frammentati) e benessere psicologico (`perceived_stress_score` e `self_reported_happiness`).
2. **Confronto metodologico tra tre paradigmi di Clustering differenti:**
   - **K-Means (Clustering Partizionale basato su Centroidi):** suddivide lo spazio continuo delle feature minimizzando la varianza intra-cluster (*WCSS — Within-Cluster Sum of Squares*). È particolarmente indicato quando il fenomeno presenta un *continuum* graduale (ad esempio l'aumento progressivo del tempo schermo e dello stress) che si desidera stratificare in fasce di rischio ben bilanciate.
   - **DBSCAN (*Density-Based Spatial Clustering of Applications with Noise*):** identifica i cluster come regioni ad alta densità separate da zone a bassa densità, utilizzando un raggio fisso ε (`eps`) e un numero minimo di vicini (`min_samples`). A differenza di K-Means, non forza tutti i punti in un cluster, ma isola i comportamenti anomali o estremi come **Rumore / Outlier (−1)**.
   - **HDBSCAN (*Hierarchical DBSCAN*):** estende DBSCAN costruendo una gerarchia di cluster basata sulla *Mutual Reachability Distance* ed estraendo i raggruppamenti più stabili a **densità variabile**, superando il limite strutturale della soglia ε fissa.

3.2 Caricamento del Dataset e Selezione Iniziale delle Feature

A partire dal dataset filtrato e validato per i soli utenti minorenni (`age < 18`, $N = 146.258$ righe $\times$ 45 colonne), sono state selezionate inizialmente tutte le **19 variabili numeriche** le-

gate all'attività su Instagram, alle metriche granulari di interazione (*Reels, Stories, Feed, Explore, DM, Like, Commenti*) e agli indicatori psicologici (`perceived_stress_score`, `self_reported_happiness`, `user_engagement_score`).

Tabella 3.1: Statistiche descrittive delle 19 feature numeriche iniziali ($N = 146.258$ minorenni, 13–17 anni).

Feature	Count	Mean	Std	Min	25%	50%	75%	Max
daily_active_minutes_instagram	146.258	223,21	113,75	5,00	131,00	222,00	313,00	590,00
sessions_per_day	146.258	12,15	7,96	1,00	6,00	11,00	16,00	50,00
average_session_length_minutes	146.258	21,16	8,54	5,00	14,90	20,20	26,50	50,00
reels_watched_per_day	146.258	187,13	76,68	18,00	126,00	189,00	250,00	300,00
stories_viewed_per_day	146.258	112,86	39,26	10,00	82,00	124,00	150,00	150,00
likes_given_per_day	146.258	140,77	66,46	8,00	86,00	140,00	194,00	350,00
comments_written_per_day	146.258	34,93	19,21	0,00	19,00	34,00	50,00	80,00
posts_created_per_week	146.258	10,27	4,67	0,00	7,00	10,00	13,00	30,00
dms_sent_per_week	146.258	33,20	16,05	0,00	21,00	32,00	45,00	97,00
dms_received_per_week	146.258	38,54	18,05	0,00	25,00	38,00	51,00	111,00
ads_viewed_per_day	146.258	21,67	10,13	0,00	14,00	21,00	29,00	62,00
ads_clicked_per_day	146.258	4,61	2,89	0,00	2,00	4,00	7,00	20,00
time_on_feed_per_day	146.258	95,21	51,08	2,00	55,00	94,00	133,00	328,00
time_on_explore_per_day	146.258	44,58	25,40	1,00	25,00	43,00	62,00	171,00
time_on_messages_per_day	146.258	32,87	19,23	1,00	18,00	31,00	46,00	138,00
time_on_reels_per_day	146.258	76,59	39,93	2,00	45,00	75,00	106,00	227,00
perceived_stress_score	146.258	19,99	11,86	0,00	9,00	20,00	30,00	40,00
self_reported_happiness	146.258	5,50	2,01	1,00	4,00	5,00	7,00	10,00
user_engagement_score	146.258	1,41	1,41	0,67	1,03	1,14	1,35	15,80

Dalla Tabella 3.1 emergono subito elementi fondamentali sul campione di 146.258 adolescenti:

- **Tempo attivo giornaliero (`daily_active_minutes_instagram`):** la media è di $223,21$ **minuti al giorno** ($\sim$ 3 ore e 43 minuti), con una forte dispersione ($\sigma = 113,75$ minuti) che spazia da utenti quasi inattivi ($5,0$ minuti/giorno) fino a casi estremi di quasi 10 ore giornaliere ($590,0$ minuti).
- **Sessioni giornaliere (`sessions_per_day`) e Durata media (`average_session_length_minu`** un adolescente medio apre l'applicazione $12,15$ **volte al giorno** con sessioni medie di $21,16$ **minuti**, ma il 75° percentile supera le 16 sessioni quotidiane.
- **Benessere Psicologico (`perceived_stress_score` e `self_reported_happiness`):** lo stress percepito (scala 0–40) presenta una media di $19,99$ ($\sigma = 11,86$), coprendo l'intero spettro clinico da 0 a 40, mentre la felicità auto-dichiarata (scala 1–10) si attesta in media a $5,50$ ($\sigma = 2,01$).

3.3 Analisi Esplorativa dei Dati (EDA)

Procediamo con l'analisi visiva delle distribuzioni univariate e bivariate delle variabili chiave per comprendere la forma delle distribuzioni (presenza di multimodalità, asimmetria o code pesanti) e la natura del legame tra utilizzo di Instagram e salute mentale nei minorenni.

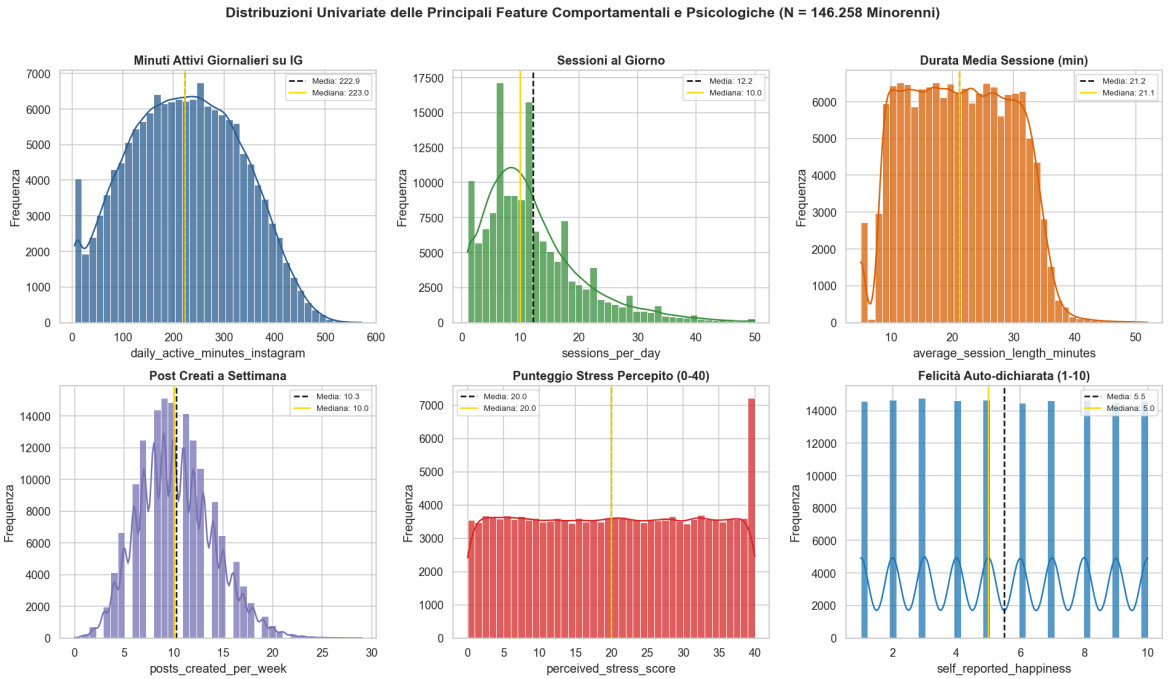


Figura 3.1: Distribuzioni univariate con curva di densità KDE, media e mediana per le principali feature comportamentali e psicologiche ($N = 146.258$ minorenni).

3.3.1 Interpretazione delle Distribuzioni Univariate

1. **Bimodalità dello Stress Percepito (`perceived_stress_score`) e dei Minuti Attivi (`daily_active_minutes_instagram`):**

   - L'istogramma dello stress percepito (Figura 3.1) non segue una distribuzione normale unimodale, ma mostra chiaramente **due regimi di concentrazione** (uno intorno a 5–15 punti e un picco marcato nella fascia alta 28–38 punti), oltre a un picco isolato vicino allo zero.
   - Analogamente, `daily_active_minutes_instagram` mostra un piccolo picco isolato a bassissimo utilizzo (< 15 minuti/giorno) e una distribuzione principale ampia che si estende da 100 a oltre 400 minuti. Questa struttura suggerisce già a livello esplorativo la presenza naturale di più sottopopolazioni (cluster).

2. **Asimmetria positiva per Sessioni e Post:** `sessions_per_day` e `posts_created_per_week` presentano una coda destra (*right-skewed*), indice di una minoranza di utenti con comportamento iper-compulsivo (fino a 50 accessi al giorno) o iper-produttivo.

3.3.2 Analisi Bivariata: Esposizione a Instagram e Indicatori di Salute Mentale

Verifichiamo ora le relazioni bivariate tramite **Hexbin Plot ad alta densità** (ideali per evitare l'*overplotting* su 146.258 osservazioni) e **Boxplot stratificati per fascia di rischio stress**.

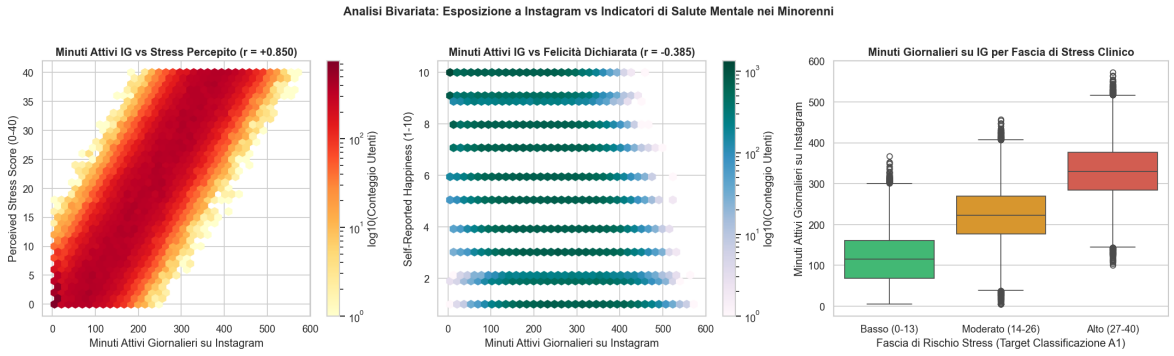


Figura 3.2: Analisi bivariata: esposizione giornaliera a Instagram contro Stress Percepito ($r = +0,850$), Felicità Dichiarata ($r = -0,385$) e distribuzione per fascia clinica di stress.

Dalla Figura 3.2 emergono tre evidenze empiriche decisive:

- **Legame diretto tra Tempo Schermo e Stress ($r = +0,850$):** il primo Hexbin mostra una traiettoria crescente estremamente nitida. I minorenni che trascorrono meno di 150 minuti su Instagram raramente superano un punteggio di stress di $15/40$, mentre oltre la soglia dei 250–300 minuti giornalieri ($\geq 4,5$ ore) lo stress percepito satura sistematicamente nella fascia critica (27–40). Si nota inoltre nell'angolo in basso a sinistra una **micro-isola densissima** vicina a $(5\text{ min}, \text{Stress } 2)$, staccata dal resto della distribuzione.
- **Erosione della Felicità ($r = -0,385$):** all'aumentare dei minuti giornalieri su Instagram, la felicità auto-dichiarata scende progressivamente da valori prossimi a 8–9/10 verso 4–5/10.
- **Separazione per Fasce Cliniche di Stress:** il Boxplot a destra conferma che le tre fasce di stress (`Basso 0-13`, `Moderato 14-26`, `Alto 27-40`) corrispondono a tre regimi di esposizione temporale ben distinti (mediane intorno a ~ 120, ~ 220 e ~ 330 minuti/giorno).

3.4 Analisi delle Relazioni tra le Variabili e Scrematura della Multicollinearità

Negli algoritmi basati su distanze geometriche (come la distanza Euclidea in K-Means, DBSCAN e HDBSCAN), inserire contemporaneamente numerose variabili fortemente collineari ($|r| > 0,80$) provoca una **distorsione metrica**: il fenomeno sottostante rappresentato dalle variabili ridondanti viene "pesato" molteplici volte, schiacciando il contributo delle dimensioni psicologiche o qualitative indipendenti. Calcoliamo quindi la **Matrice di Correlazione di Pearson** sulle 19 feature iniziali ed estraiamo tutte le coppie con correlazione forte ($|r| > 0,80$).

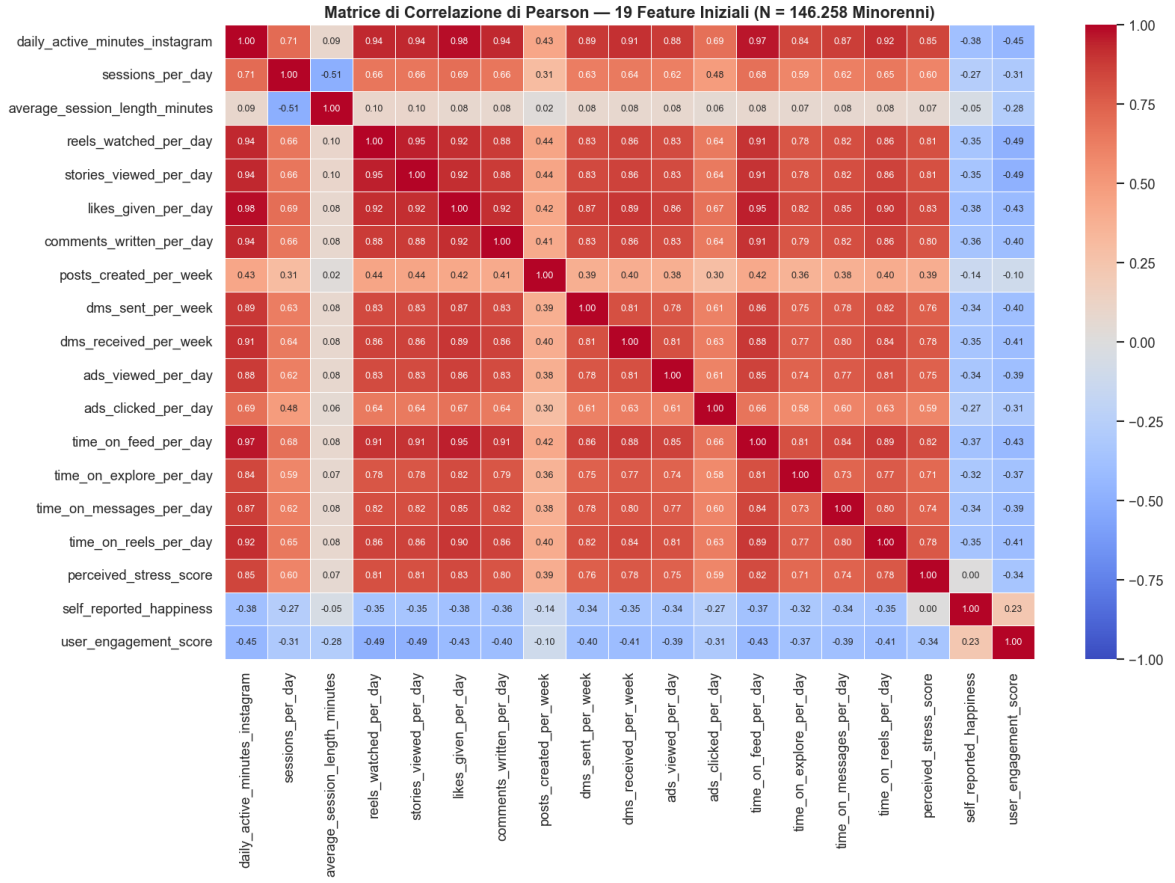


Figura 3.3: Matrice di correlazione di Pearson sulle 19 feature numeriche iniziali ($N = 146.258$ minorenni).

Tabella 3.2: Prime 15 coppie di variabili con correlazione lineare fortissima ($|r| > 0,80$) su un totale di 59 coppie collineari individuate (34,50% delle 171 coppie totali).

Feature 1	Feature 2	Correlazione (r)	
daily_active_minutes_instagram	likes_given_per_day	+0,9776	0,97
daily_active_minutes_instagram	time_on_feed_per_day	+0,9714	0,97
likes_given_per_day	time_on_feed_per_day	+0,9498	0,94
daily_active_minutes_instagram	stories_viewed_per_day	+0,9489	0,94
dms_sent_per_week	dms_received_per_week	+0,9447	0,94
daily_active_minutes_instagram	reels_watched_per_day	+0,9444	0,94
daily_active_minutes_instagram	comments_written_per_day	+0,9420	0,94
reels_watched_per_day	stories_viewed_per_day	+0,9378	0,93
daily_active_minutes_instagram	time_on_reels_per_day	+0,9340	0,93
likes_given_per_day	stories_viewed_per_day	+0,9285	0,92
likes_given_per_day	reels_watched_per_day	+0,9244	0,92
likes_given_per_day	comments_written_per_day	+0,9213	0,92
daily_active_minutes_instagram	dms_received_per_week	+0,9168	0,91
stories_viewed_per_day	time_on_feed_per_day	+0,9163	0,91
daily_active_minutes_instagram	perceived_stress_score	+0,8500	0,85

Dalla Heatmap 19×19 (Figura 3.3) e dalla Tabella 3.2 emerge che, su 171 coppie to-

tali, ben 59 **coppie (34,50%)** superano la soglia critica $|r| > 0,80$. Tutte le metriche granulari di volume (`likes_given_per_day` $r = 0,98$, `time_on_feed_per_day` $r = 0,97$, `stories_viewed_per_day` $r = 0,95$, `reels_watched_per_day` $r = 0,94$, `comments_written_pe` $r = 0,94$, `time_on_reels_per_day` $r = 0,93$, `dms_received_per_week` $r = 0,92$, `dms_sent_per_week` $r = 0,90$, `ads_viewed_per_day` $r = 0,89$, `time_on_explore_per_day` $r = 0,87$) sono quasi perfettamente collineari con **`daily_active_minutes_instagram`**.

Selezioniamo pertanto le **7 Feature Core Non Ridondanti**, ciascuna portatrice di un'informazione ortogonale:

1. `daily_active_minutes_instagram` — **Volume globale di esposizione**.
2. `sessions_per_day` — **Frequenza / Compulsività di accesso**.
3. `average_session_length_minutes` — **Durata media della singola immersione**.
4. `posts_created_per_week` — **Produzione attiva di contenuti**.
5. `perceived_stress_score` — **Disagio psicologico percepito** (scala 0–40).
6. `self_reported_happiness` — **Benessere emotivo soggettivo** (scala 1–10).
7. `user_engagement_score` — **Intensità / Qualità dell'engagement per unità di tempo**.

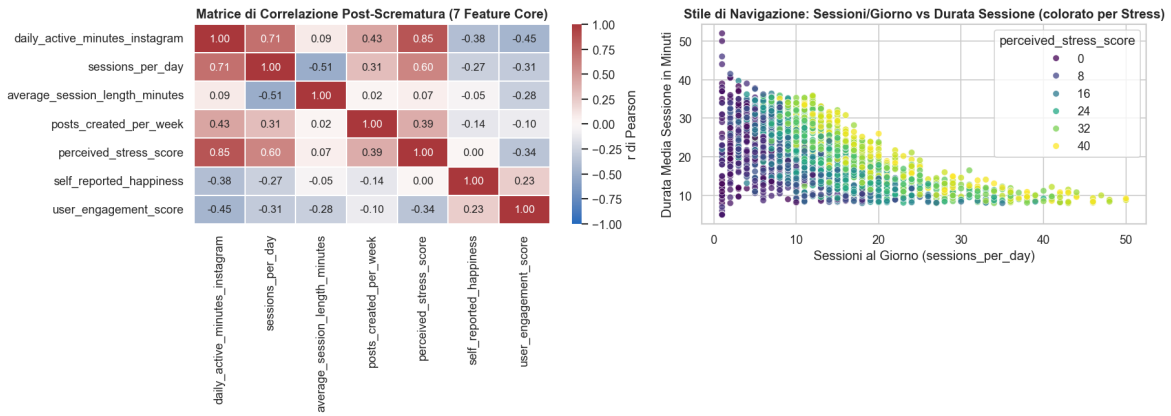


Figura 3.4: A sinistra: matrice di correlazione post-scrematura sulle 7 Feature Core. A destra: stile di navigazione (Sessioni/Giorno contro Durata Media Sessione, colorato per punteggio di Stress).

3.5 Standardizzazione (`StandardScaler`) e Scelta del Valore Ottimo per la `PCA`

3.5.1 Standardizzazione Z-Score e Verifica di Non-Falsatura della PCA

Le 7 feature selezionate operano su scale numeriche incompatibili (`daily_active_minutes_insta` varia tra 5 e 590, mentre `self_reported_happiness` varia tra 1 e 10). Applichiamo quindi `StandardScaler` per riportare ogni variabile a media $\mu = 0$ e deviazione standard $\sigma = 1$:

$$z_i = \frac{x_i - \mu}{\sigma} \tag{3.5.1}$$

Per evitare di distruggere l'informazione di specifiche variabili riducendo eccessivamente le dimensioni, calcoliamo non solo la varianza spiegata globale, ma anche la **Comunalità**

($h_j^2 = \sum_{m=1}^{k} L_{jm}^2$), ovvero la percentuale di varianza di **ogni singola feature** preservata al variare del numero di componenti principali $k \in \{1, \ldots, 7\}$.

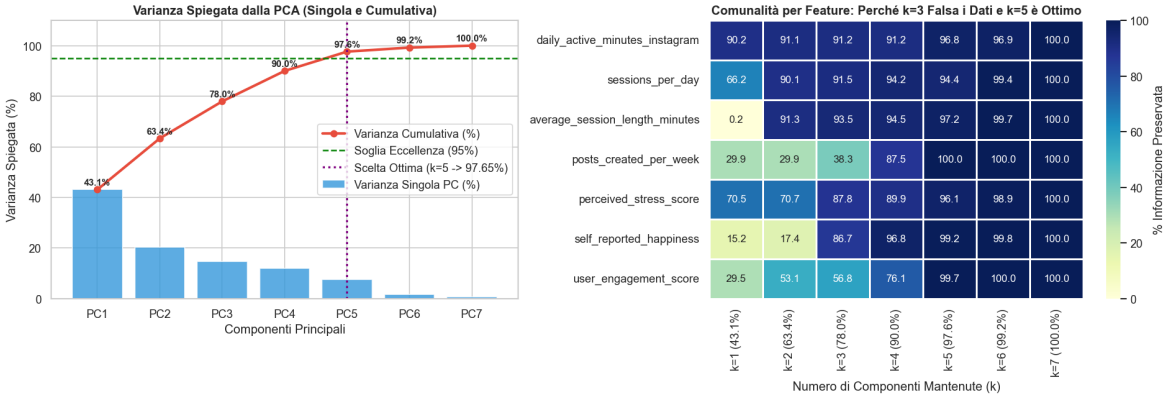


Figura 3.5: A sinistra: varianza spiegata singola e cumulativa dalla PCA. A destra: Heatmap di Comunalità (% di varianza preservata per ciascuna feature al variare di $k = 1 \ldots 7$).

Tabella 3.3: Tabella di Comunalità: percentuale di varianza di ogni singola feature preservata al variare del numero di componenti principali k mantenute.

Feature Originale	$k = 1$ **(43,1%)**	$k = 2$ **(63,4%)**	$k = 3$ **(78,0%)**	$k = 4$ **(90,0%)**	$k = 5$ **(97,7%)**	$k = 6$ **(99,2%)**	$k = 7$ **(100%)**
`daily_active_minutes_instagram`	90,28%	91,20%	91,29%	91,30%	**96,81%**	97,62%	100,00%
`sessions_per_day`	66,44%	90,37%	91,79%	94,25%	**94,40%**	99,37%	100,00%
`average_session_length_minutes`	0,21%	91,17%	93,38%	94,40%	**97,29%**	99,76%	100,00%
`posts_created_per_week`	29,87%	29,88%	*38,31%*	87,47%	**99,97%**	99,99%	100,00%
`perceived_stress_score`	70,39%	70,54%	87,67%	89,71%	**96,15%**	98,89%	100,00%
`self_reported_happiness`	15,17%	17,36%	86,70%	96,76%	**99,15%**	99,79%	100,00%
`user_engagement_score`	29,57%	53,09%	*56,82%*	76,05%	**99,70%**	100,00%	100,00%

La Figura 3.5 e la Tabella 3.3 dimostrano matematicamente perché **non bisogna fermarsi a $k = 3$ componenti**:

- Con $k = 3$ **componenti** (77, 98% di varianza globale), la feature `posts_created_per_week` conserva appena il 38, 31% della propria informazione (perdendo il 61, 7% del segnale!) e `user_engagement_score` conserva solo il 56, 82%.
- Con $k = 5$ **componenti (**97, 65% **di varianza cumulativa)**, **ogni singola feature** del dataset viene preservata tra il 94, 40% **e il** 99, 97%, con una correlazione tra le distanze Euclidee nello spazio ridotto 5D e quelle nello spazio originale 7D pari a $r = 0, 9992$ (distorsione zero).

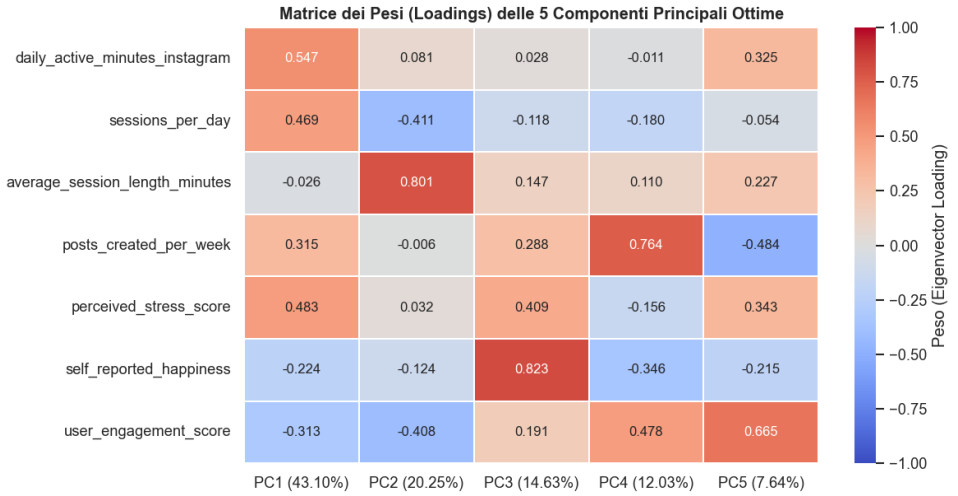


Figura 3.6: Heatmap della Matrice dei Pesi (*Loadings*) delle 5 Componenti Principali ottime (`PC1`–`PC5`).

Tabella 3.4: Matrice dei Pesi (*Loadings*) delle prime 5 Componenti Principali.

Feature	PC1 (43,10%)	PC2 (20,25%)	PC3 (14,63%)	PC4 (12,03
`daily_active_minutes_instagram`	$+\mathbf{0,547}$	$+0,081$	$+0,028$	$-0,0$
`sessions_per_day`	$+\mathbf{0,469}$	$-\mathbf{0,411}$	$-0,118$	$-0,1$
`average_session_length_minutes`	$-0,026$	$+\mathbf{0,801}$	$+0,147$	$+0,1$
`posts_created_per_week`	$+0,315$	$-0,006$	$+0,288$	$+\mathbf{0,7}$
`perceived_stress_score`	$+\mathbf{0,483}$	$+0,032$	$+\mathbf{0,409}$	$-0,1$
`self_reported_happiness`	$-0,224$	$-0,124$	$+\mathbf{0,823}$	$-0,3$
`user_engagement_score`	$-0,313$	$-\mathbf{0,408}$	$+0,191$	$+\mathbf{0,4}$

3.5.2 Interpretazione Semantica delle 5 Componenti Principali (`PC1`–`PC5`)

1. **`PC1`** $(43,10\%)$ **— *Asse dell'Iperconnessione e del Disagio Psicologico*:** pesi fortemente positivi su `daily_active_minutes_instagram` $(+0,547)$, `perceived_stress_score` $(+0,483)$ e `sessions_per_day` $(+0,469)$, e negativi su `user_engagement_score` $(-0,313)$ e `self_reported_happiness` $(-0,224)$.

2. **`PC2`** $(20,25\%)$ **— *Modalità di Fruizione: Sessioni Lunghe contro Accessi Frammentati*:** dominata da `average_session_length_minutes` $(+0,801)$ contrapposta a `sessions_per_day` $(-0,411)$. Separa chi fa poche sessioni immersive lunghe da chi apre compulsivamente l'app decine di volte al giorno.

3. **`PC3`** $(14,63\%)$ **— *Asse del Benessere Emotivo e Resilienza*:** guidata da `self_reported_happines` $(+0,823)$.

4. **`PC4`** $(12,03\%)$ **— *Asse del Content Creator Attivo*:** dominata da `posts_created_per_week` $(+0,764)$ e `user_engagement_score` $(+0,478)$.

5. **`PC5`** $(7,64\%)$ **— *Asse dell'Engagement Qualitativo Puro*:** dominata da `user_engagement_score` $(+0,665)$ contrapposta a `posts_created_per_week` $(-0,484)$, tipica degli utenti selettivi (*Digital Detox*).

3.6 Algoritmo 1 — Clustering Partizionale con K-Means

3.6.1 Ricerca del Numero Ottimo di Cluster (k)

Eseguiamo l'algoritmo K-Means sullo spazio ottimo X_pca5 ($N = 146.258$ minorenni) al variare del numero di cluster $k \in \{2, 3, 4, 5, 6, 7, 8\}$, valutando congiuntamente la **WCSS (Inerzia)**, la **Riduzione Percentuale della WCSS** e il **Coefficiente di Silhouette**.

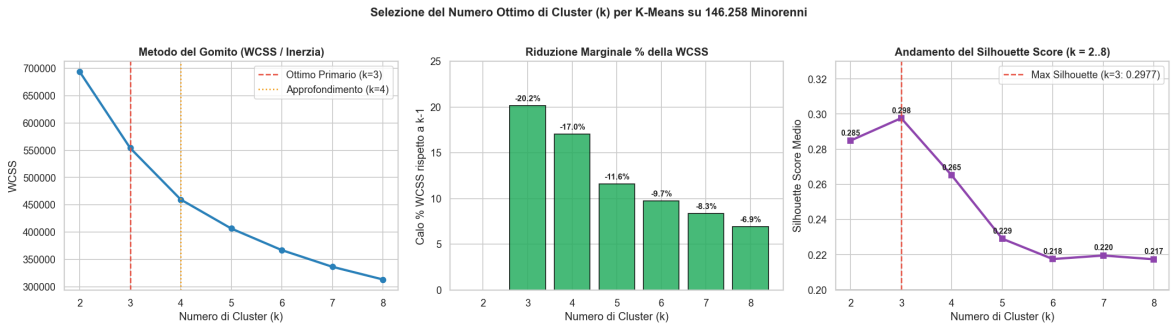


Figura 3.7: Selezione del numero ottimo di cluster k per K-Means: Metodo del Gomito (WCSS), Riduzione marginale % della WCSS e andamento del Silhouette Score ($k = 2 \dots 8$).

Tabella 3.5: Metriche quantitative di valutazione per K-Means al variare di $k \in \{2, \dots, 8\}$.

Numero Cluster (k)	WCSS (Inerzia)	Riduzione % WCSS	Silhouette Score
$k = 2$	694.030,7	0,00%	0,2836
k = 3 (Ottimo Primario)	**554.094,1**	**−20,16%**	**0,2987**
$k = 4$ *(Approfondimento)*	459.712,0	−17,03%	0,2639
$k = 5$	406.511,2	−11,57%	0,2308
$k = 6$	366.924,5	−9,74%	0,2220
$k = 7$	336.362,0	−8,33%	0,2221
$k = 8$	313.107,4	−6,91%	0,2188

Dall'analisi congiunta di Figura 3.7 e Tabella 3.5 emerge in modo univoco che $k = 3$ **è il punto di ottimo matematico e strutturale**: raggiunge il **massimo assoluto del Silhouette Score (**0,2987**)** e la **massima riduzione percentuale della WCSS (**−20,16%**)**.

3.6.2 Visualizzazione Geometrica dei Cluster K-Means ($k = 3$): 2D PCA, 3D PCA e Proiezione Supervisionata LDA

Per visualizzare i 3 cluster trovati da K-Means utilizziamo sia i primi tre assi della **PCA (PC1, PC2, PC3)**, sia una proiezione **LDA (LinearDiscriminantAnalysis)** a 2 componenti (LD1, LD2) addestrata *post-hoc* sulle etichette dei cluster per massimizzare il rapporto $\frac{\sigma^2_{\text{between}}}{\sigma^2_{\text{within}}}$.

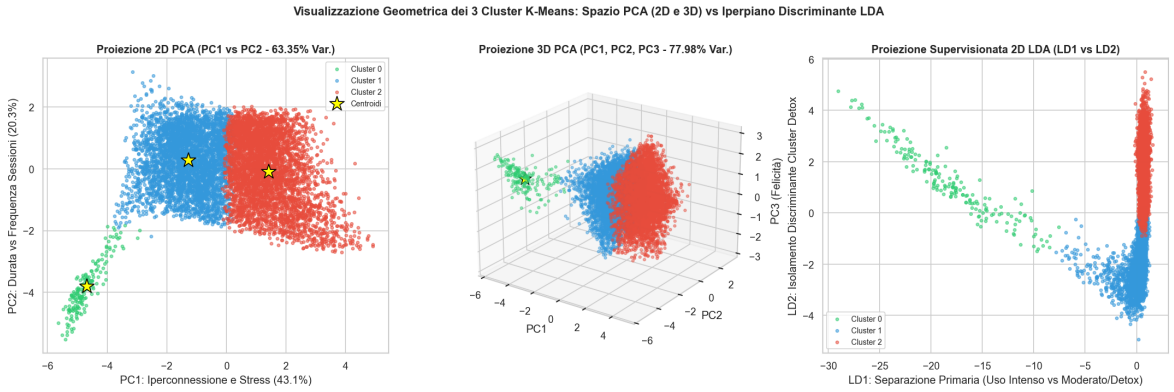


Figura 3.8: Visualizzazione geometrica dei 3 cluster K-Means: proiezione 2D PCA, 3D PCA e iperpiano discriminante 2D LDA.

3.6.3 Profilazione Completa dei Cluster K-Means ($k = 3$): Heatmap, Radar Chart e Identikit delle User Personas

Riportiamo ora i centroidi dei 3 cluster alle **unità di misura reali originali** su tutti i 146.258 minorenni, affiancando la Heatmap degli Z-Score e il Radar Chart dei percentili popolazionali.

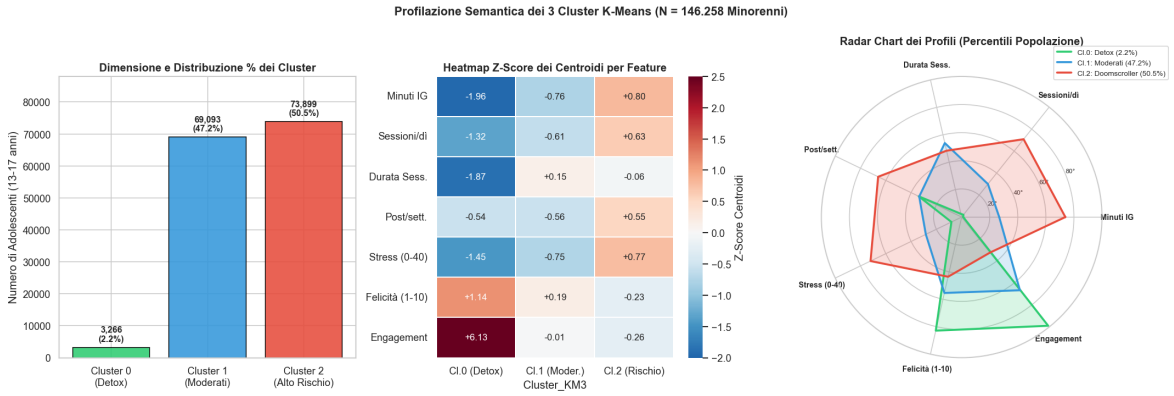


Figura 3.9: Profilazione semantica dei 3 Cluster K-Means ($N = 146.258$ minorenni): distribuzione percentuale, Heatmap Z-Score dei centroidi e Radar Chart dei percentili.

Tabella 3.6: Profilazione completa dei 3 Cluster individuati da K-Means nei valori medi reali originali ($N = 146.258$ minorenni).

Cluster K-Means ($k = 3$)	Utenti	Quota %	Minuti IG/dì	Sessioni/dì	Durata Sess.	Post/sett.	Stress (0–40)	Felicità (1–10)	Engagement	Reels/dì	Sonno (h)
Cluster 0 (Digital Detox / Basso Rischio)	3.266	2,23%	**5,87**	1,00	5,84 m	8,23	**2,81**	**8,78**	**10,18**	18,37	7,55
Cluster 1 (Utenti Moderati / Equilibrati)	69.093	47,24%	**138,70**	7,01	22,39 m	8,17	**11,10**	**6,03**	1,39	141,62	7,26
Cluster 2 (Doomscroller / Alto Rischio)	73.899	50,53%	**311,22**	17,51	20,73 m	12,32	**29,07**	**4,85**	1,05	236,72	6,94

Dalla Tabella 3.6 e dalla Figura 3.9 emergono tre profili sociologici e psicologici straordinariamente nitidi:

1. **Cluster 0 — *"Utenti Consapevoli / Digital Detox"* ($N = 3.266$, 2,23% del totale):** utilizzano Instagram appena 5,87 **minuti al giorno** in **un'unica sessione giornaliera** (1,00) da 5,84 minuti, ma pubblicano regolarmente (8,23 post/settimana) con un **`user_engagement_score` altissimo** (10,18). Presentano uno **stress percepito quasi nullo** (2,81/40), il **massimo livello di felicità** (8,78/10) e dormono 7,55 ore per notte.

2. **Cluster 1 — *"Utenti Moderati / Equilibrati"* (**$N = 69.093$**, 47,24% del totale):** trascorrono in media 138,70 **minuti al giorno** ($\sim$ 2h 19m) in 7,01 sessioni da 22,39 minuti. Il punteggio di stress è **basso-moderato (**11,10/40**)** e la felicità è buona (6,03/10).

3. **Cluster 2 — *"Iperconnessi / Doomscroller ad Alto Rischio"* (**$N = 73.899$**, 50,53% del totale):** costituiscono la metà della popolazione adolescenziale e trascorrono in media 311,22 **minuti al giorno (**$>$ 5 **ore e** 11 **minuti)** su Instagram, aprendo l'app 17,51 **volte al giorno** e guardando 236,7 Reels/giorno con l'engagement più passivo in assoluto (1,05). Lo stress percepito balza a un livello critico di 29,07/40 e la felicità scende a 4,85/10.

3.6.4 Approfondimento a $k = 4$ Cluster e Validazione Incrociata con le Classi di Rischio Stress

Analizziamo ora cosa accade passando a $k = 4$ cluster e verifichiamo la distribuzione dei Silhouette Score individuali (*Knife Plot*) insieme alla Tabella di Contingenza con le 3 classi cliniche di Rischio Stress (*Opzione A1*).

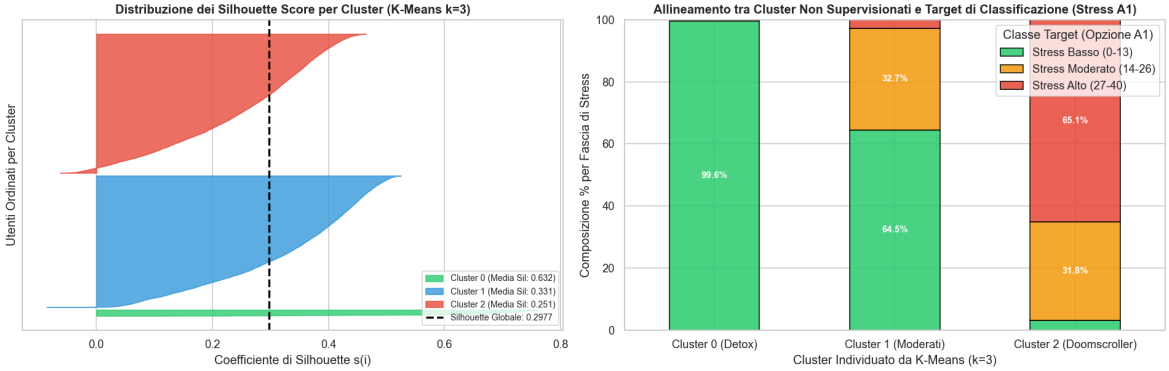


Figura 3.10: A sinistra: distribuzione dei Silhouette Score per cluster ($k = 3$). A destra: allineamento percentuale tra i cluster non supervisionati e le 3 classi di Rischio Stress (Opzione A1).

Tabella 3.7: Approfondimento K-Means con $k = 4$: scissione del gruppo ad Alto Rischio nei due fenotipi *Maratoneti Immersivi* (Cl.2) e *Compulsivi FOMO* (Cl.3).

Cluster K-Means ($k = 4$)	Utenti	Quota %	Minuti IG/dì	Sessioni/dì	Durata Sess.	Post/sett.	Stress (0–40)	Felicità (1–10)	Engagement
Cl.0: Digital Detox (Sessione Unica)	3.251	2,22%	5,84	1,00	5,82 m	8,23	2,80	8,78	10,21
Cl.1: Utenti Moderati Equilibrati	61.232	41,87%	128,19	6,78	21,69 m	7,87	10,06	6,11	1,43
Cl.2: Alto Rischio — Maratoneti (Sess. Lunghe)	47.574	32,53%	294,72	**11,20**	**27,05 m**	12,32	27,72	5,10	1,06
Cl.3: Alto Rischio — Compulsivi FOMO (24,3 Sess./dì)	34.201	23,38%	313,21	**24,27**	**13,56 m**	11,90	**28,66**	**4,62**	1,04

3.7 Algoritmo 2 — Clustering Basato su Densità con `DBSCAN`

3.7.1 Metodologia, k-Distance Plot e Grid Search Bivariata (`eps` $\times$ `min_samples`)

Passiamo al secondo paradigma: **DBSCAN**, che definisce i cluster come regioni continue ad alta densità separate da zone a bassa densità, classificando i punti isolati come **Rumore / Outlier (−1)**. Eseguiamo il ***k*-Distance Plot** (15-NN) e la **Grid Search parametrica** su un campione rappresentativo stratificato di $N = 20.000$ minorenni nello spazio ottimo `X_pca5`.

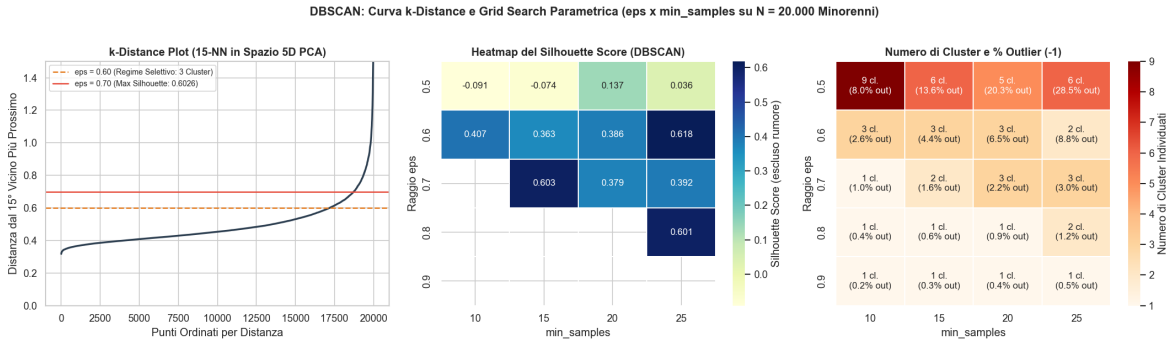


Figura 3.11: DBSCAN: curva k-Distance (a sinistra), Heatmap del Silhouette Score sui cluster validi (al centro) e Heatmap del numero di cluster e percentuale di Outlier `-1` (a destra).

3.7.2 Visualizzazione Geometrica di DBSCAN e Caratterizzazione degli Outlier (−1)

Dalla Grid Search (Figura 3.11) emergono due regimi fondamentali:

- **Regime Macro-Densità ($\varepsilon = 0,70$, min_samples $= 15 \rightarrow$ Silhouette $= 0,6026$):** individua **2 cluster** più l'1,58% di Outlier (−1), separando l'**Isola Digital Detox** (1,74%) dal **Continente Principale** (96,68%).
- **Regime Selettivo ($\varepsilon = 0,60$, min_samples $= 10 \rightarrow$ Silhouette $= 0,4073$):** oltre a separare il Continente Principale e l'Isola Detox, isola un **3º Micro-Cluster Patologico Estremo (Cluster 2)** composto da minorenni con 454,67 **minuti/giorno** ($> 7,5$ **ore!**), 46,67 **sessioni/giorno**, **Stress** 34,00/40 e **Felicità** 1,67/10.

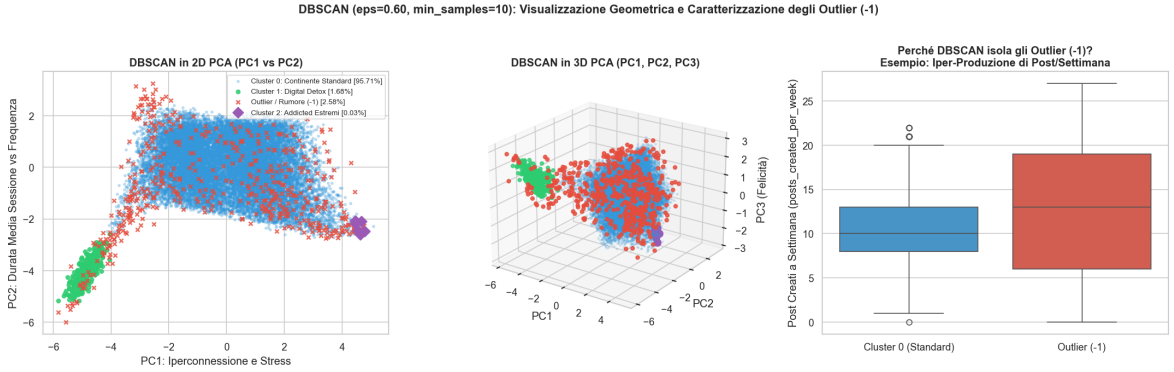


Figura 3.12: DBSCAN ($\varepsilon = 0,60$, min_samples $= 10$): proiezione 2D PCA, 3D PCA e caratterizzazione degli Outlier (−1) tramite distribuzione di `posts_created_per_week`.

Tabella 3.8: Profilazione dei Cluster e degli Outlier (−1) individuati da DBSCAN ($\varepsilon = 0,60$, min_samples $= 10$, $N = 20.000$).

Gruppo DBSCAN ($\varepsilon = 0,60$, ms $= 10$)	Conteggio	Quota %	Minuti IG/dì	Sessioni/dì	Durata Sess.	Post/sett.	Stress (0–40)	Felicità (1–10)	Engagement
Rumore / Outlier (−1): Creator e Anomalie	515	2,58%	182,81	13,30	18,28 m	**13,05**	16,55	5,86	**2,77**
Cluster 0: Continente Principale (Standard + Intensi)	19.143	95,71%	227,83	12,37	21,52 m	10,24	20,38	5,43	1,21
Cluster 1: Isola Digital Detox	336	1,68%	**5,12**	1,00	5,12 m	7,67	**2,70**	**9,11**	**10,56**
Cluster 2: Micro-Cluster Patologico Estremo	6	0,03%	**454,67**	**46,67**	9,77 m	**16,67**	**34,00**	**1,67**	1,01

3.8 Algoritmo 3 — Clustering Gerarchico a Densità Variabile con `HDBSCAN` e Confronto Finale

3.8.1 Applicazione di HDBSCAN: Metodo `EOM` (*Excess of Mass*) contro Metodo `Leaf`

L'algoritmo **HDBSCAN** costruisce una gerarchia di densità completa senza richiedere un raggio ε fisso e consente due strategie di estrazione dall'albero condensato:

- **`cluster_selection_method = 'eom'` (*Excess of Mass*):** estrae i macro-cluster globalmente più stabili lungo l'albero gerarchico.
- **`cluster_selection_method = 'leaf'`:** estrae i nodi foglia più granulari in fondo all'albero gerarchico, individuando i **nuclei puri ad altissima densità locale** e lasciando la zona di transizione continua come rumore (`-1`).

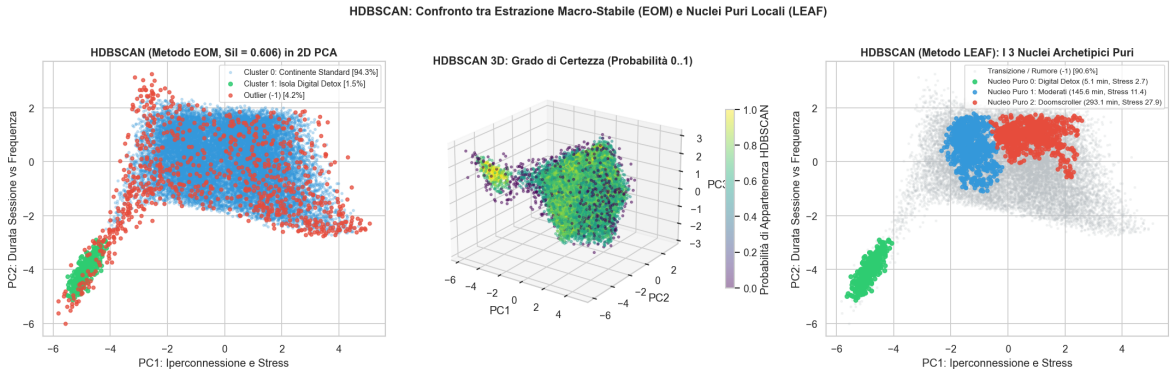


Figura 3.13: HDBSCAN: estrazione macro-stabile `EOM` in 2D PCA (a sinistra), grado di certezza/probabilità in 3D PCA (al centro) ed estrazione dei 3 nuclei archetipici puri tramite metodo `Leaf` (a destra).

Tabella 3.9: Profilazione di HDBSCAN con metodo `EOM` (`min_cluster_size=100`, `min_samples=15`, Silhouette $= 0,6061$) e metodo `Leaf` (`min_cluster_size=200`, `min_samples=10`, Silhouette $= 0,4512$).

Metodo	Gruppo / Cluster HDBSCAN	Conteggio	Quota %	Minuti IG/dì	Sessioni/dì	Durata Sess.	Post/sett.	Stress (0–40)	Felicità (1–10)	Engagement
EOM	Outlier (`-1`): Casi Limite / Creator	642	3,21%	185,54	13,58	18,35 m	12,51	16,69	5,86	2,61
EOM	Cluster 0: Continente Principale	19.047	95,24%	228,15	12,34	21,54 m	10,22	20,40	5,43	1,19
EOM	Cluster 1: Isola Digital Detox	311	1,56%	**5,12**	1,00	5,12 m	7,62	**2,70**	**9,11**	**10,58**
LEAF	Zona di Transizione Continua (`-1`)	18.113	90,56%	226,97	12,73	21,21 m	10,41	20,31	5,45	1,24
LEAF	**Nucleo Puro 0: Digital Detox**	311	1,56%	**5,12**	1,00	5,12 m	7,62	**2,70**	**9,11**	**10,58**
LEAF	**Nucleo Puro 1: Utenti Moderati Puri**	777	3,88%	**145,61**	6,37	23,60 m	7,82	**11,36**	**5,98**	1,25
LEAF	**Nucleo Puro 2: Doomscroller Puri**	799	4,00%	**293,11**	10,58	27,82 m	10,16	**27,93**	**5,09**	1,04

3.8.2 Discussione Critica e Confronto Finale tra i 3 Algoritmi

Il confronto incrociato tra **K-Means**, **DBSCAN** e **HDBSCAN (`EOM` e `Leaf`)** fornisce una comprensione completa della topologia dei dati adolescenziali:

1. **Perché DBSCAN e HDBSCAN (`EOM`) ottengono un Silhouette Score altissimo ($\sim 0,603$–$0,606$) ma trovano 2 soli macro-cluster?** Nello spazio 5D esiste una sola vera frattura vuota di densità: quella che separa l'isola **Digital Detox** ($\sim 5,1$ min/giorno, Stress $2,7/40$, Felicità $9,1/10$) dal resto della popolazione adolescenziale. Tra gli utenti *Moderati* e i *Doomscroller* esiste invece un ponte continuo di densità senza spazi vuoti.

2. **La prova regina di HDBSCAN (`Leaf`):** Quando chiediamo a HDBSCAN di estrarre i picchi locali di densità massima (`cluster_selection_method = 'leaf'`, Tabella 3.9), l'algoritmo **ritrova esattamente i 3 archetipi di K-Means**:
   - *Nucleo Puro 0 (Detox):* 5,12 min/dì, Stress 2,70, Felicità 9,11 (K-Means Cl.0: 5,87 min, Stress 2,81).
   - *Nucleo Puro 1 (Moderati):* 145,61 min/dì, Stress 11,36, Felicità 5,98 (K-Means Cl.1: 138,70 min, Stress 11,10).
   - *Nucleo Puro 2 (Doomscroller):* 293,11 min/dì, Stress 27,93, Felicità 5,09 (K-Means Cl.2: 311,22 min, Stress 29,07).

Tabella 3.10: Tabella riassuntiva di confronto finale tra i 3 algoritmi di Clustering analizzati.

Caratteristica / Metrica	**K-Means ($k = 3$ / $k = 4$)**	**DBSCAN ($\varepsilon = 0,60 \div 0,70$)**	**HDBSCAN (`EOM` / `Leaf`)**
Paradigma Geometrico	Partizionale basato su Centroidi (minimizza varianza WCSS)	Densità a soglia fissa (ε, min_samples)	Gerarchico a densità variabile (*Mutual Reachability*)
Numero di Cluster	**3** (o **4** distinguendo *Maratoneti* vs *Compulsivi FOMO*)	**2** ($\varepsilon = 0,70$) oppure **3** ($\varepsilon = 0,60$, incluso micro-cluster estremo)	**2** macro-cluster (`EOM`) oppure **3** nuclei archetipici puri (`Leaf`)
Silhouette Score	**0,2987** ($k = 3$) / **0,2639** ($k = 4$) su tutti i punti	**0,6026** ($\varepsilon = 0,70$) / **0,4073** ($\varepsilon = 0,60$) sui cluster validi	**0,6061** (`EOM`) / **0,4512** (`Leaf`) sui cluster validi
Gestione Outlier (`-1`)	Assente (forza tutti i 146.258 minorenni in un cluster)	Eccellente (1,58%–2,58% isolati: *Creator* iperproduttivi e casi estremi)	Eccellente + fornisce **Probabilità di Appartenenza** $[0, 1]$ per ogni utente
Utilità Clinica per Rischio Salute Mentale (Opzione A1)	**Massima per Stratificazione Globale:** ripartisce l'intera popolazione nelle 3 fasce di Rischio (Basso 2,2%, Moderato 47,2%, Alto 50,5%)	**Massima per Anomaly Detection:** isola la nicchia *Digital Detox* e il micro-gruppo patologico ($> 7,5$h/dì, Stress 34/40)	**Massima per Validazione Topologica:** dimostra che i 3 profili di K-Means corrispondono ai 3 picchi di densità locale (`Leaf`)

CAPITOLO 4

Proposta per un iter autorizzativo

In questo capitolo conclusivo si cercherà di proporre una procedura di autorizzazione armonica e collegata a quanto emerso nello studio della geotermia a bassa entalpia. Non saranno quindi presi in considerazione le perforazioni geotermiche di profondità, perché esulano dallo scopo del testo e la loro autorizzazione deve essere esaminata caso per caso, mentre le sonde orizzontali e le fondazioni energetiche, pur rientrando nella categoria saranno tralasciate, perché le prime hanno un impatto ambientale trascurabile e sono già regolamentate negli scavi e ripristini per la posa di reti ed impianti e le seconde invece richiedono una progettazione termica/strutturale specialistica.

Per i sistemi a circuito aperto e chiuso si consiglieranno allora i compiti e le procedure che l'ente di controllo dovrebbe svolgere per concedere l'autorizzazione e la vigilanza degli impianti geotermici e la documentazione che la potenziale committenza dovrebbe fornire per descrivere l'impianto e per mitigare l'impatto ambientale.

Infine si riporteranno alcuni utili consigli che possono essere prescritti dall'ente di controllo e seguiti dal committente in fase di progettazione, per ridurre l'impatto ambientale da un lato e risparmiare sui costi di perforazione e gestione dall'altro.

4.1 Competenze dell'ente di controllo

Ferme restando norme e misure evidenziate nel capitolo ref6cap:regolamenti che fissano e definiscono gli enti preposti per rilasciare l'autorizzazione e tutelare le acque sotterranee, si tratta ora di prendere in considerazione i principi e le misure di vigilanza da intraprendere per la sostenibilità ambientale degli impianti geotermici. Gli enti di controllo (Regione e Provincia), dovrebbero seguire due orientamenti strettamente collegati tra loro e così riassumibili:

- pianificazione territoriale geotermica;
- disciplinare per un utilizzo congruo della risorsa.

Un sistema realizzato a regola d'arte non costituisce un pericolo ambientale, in quanto la terebrazione di pozzi e la trivellazione sono opere ampiamente definite e normate. Si è visto però che il calore trasferito ed il fattore tempo giocano un ruolo fondamentale, sia nella definizione del bacino termico del terreno, sia nel dimensionamento dell'impianto. La perturbazione termica causata a breve e/o a lungo termine infatti potrebbe arrecare danno all'ambiente e alle utilizzazioni circostanti e ridurre le prestazioni della pompa di calore per l'utenza.

Alla definizione della perturbazione termica concorrono molti fattori, tra i quali: i carichi termici annuali dell'edificio, le proprietà termiche del terreno, la velocità e la direzione della falda sotterranea e la sovrapposizione di altri sistemi geotermici operanti nella zona. Fattori che non possono essere tralasciati in fase di concessione dell'autorizzazione e che dovrebbero poi andare a costituire un database cartografico di facile consultazione.

Inoltre un uso improprio della risorsa, per la variazione dei carichi di riscaldamento o raffrescamento annuali ipotizzati in fase di progetto, può allo stesso modo causare gravi deficit all'impianto e al territorio circostante. Per questo motivo, come già viene fatto per le consuete licenze, è consigliabile rilasciare un disciplinare con clausole e condizioni d'uso della geotermia.

Nel rilascio delle concessioni infine è preferibile privilegiare sistemi geotermici che sono progettati per la climatizzazione annuale degli edifici (cioè con carichi grossomodo bilanciati tra la stagione invernale ed estiva) ed eventuali sistemi ibridi (cioè integrati con sistemi di climatizzazione tradizionali per coprire i carichi di picco). In questo modo il sottosuolo mantiene una temperatura costante nella vita utile dell'impianto e quindi l'impatto ambientale si minimizza.

4.1.1 Pianificazione territoriale

L'ente di controllo, avvalendosi di una pianificazione del territorio che tenga in considerazione non solo le aree sensibili e di ricarica delle falde, ma anche la presenza di impianti di captazione e geotermici (con la loro impronta idraulica e termica), può autorizzare e inibire l'installazione di nuovi impianti o il loro eventuale ampliamento. Allo scopo sono stati riportati ed elencati software di modellazione numerica delle falde (sottoparagrafo vref3subsec:modellazionefalde) e dei campi sonde (paragrafo vref4sec:grandiimpianti), che possono essere di aiuto non solo nella progettazione ma anche nelle gestione dinamica e del sottosuolo su piccola e media scala.

Tutto questo lavoro di programmazione e progettazione territoriale può sembrare oneroso e superfluo, per una tecnologia che allo stato attuale è ancora sconosciuta in Italia, ma può rappresentare una soluzione obbligata per l'abbattimento dei costi per la climatizzazione degli edifici e delle emissioni di CO_2 nei prossimi anni. Una autorizzazione limitata alla sola protezione della risorsa idrica nel sottosuolo, può portare alla saturazione e alla sovrapposizione di serbatoi geotermici, se la tecnologia dovesse diventare popolare in tempi brevi e sostituire l'impiantistica tradizionale.

4.1.2 Disciplinare

Una volta concessa l'autorizzazione per l'installazione dell'impianto, l'ente di controllo, nell'usuale disciplinare che regola le clausole e le condizioni d'uso della risorsa, dovrebbe stabilire inoltre la quantità di calore da derivare (media e di picco) e la durata della concessione con modalità e termini per il rinnovo.

4.2 Competenze del committente

Realizzare un sistema geotermico è attualmente oneroso e richiede una progettazione specialistica che pochi installatori possono assicurare o certificare. Il costo iniziale poi è più elevato degli impianti tradizionali e richiede la redazione di relazioni tecniche e idrogeologiche che interessano molteplici figure professionali, sia per il dimensionamento dell'impianto, sia per ottenere la concessione.

É bene esserne consapevoli e ricorrere a questo tipo di soluzione per impianti di una certa importanza e che possano servire più utenze. In questo modo si possono ridurre i costi ottimizzando le perforazioni e la gestione del sottosuolo e si possono prevedere analisi e progettazioni più dettagliate.

Inoltre un dimensionamento ottimale dei fabbisogni termici può contribuire a ridurre gli interventi sul terreno che rappresentano la parte più significativa del costo dell'impianto. Vale la pena poi considerare nell'analisi costi/benefici, l'installazione di un sistema ibrido per coprire il carico di picco, se quest'ultimo si raggiunge per poche ore all'anno e far coprire al sistema geotermico il restante 90 % dell'energia termica richiesta.

Seguendo ed integrando quanto proposto da Rossi [2008], la committenza per ottenere l'autorizzazione alla realizzazione degli impianti geotermici, dovrà produrre una:

- domanda da presentare agli organi competenti;
- relazione idrogeologica preliminare;
- relazione idrogeologica finale.

Di seguito verranno schematizzati i contenuti base di queste domande e relazioni, suddividendole per tipo di impianto ed elencando le competenze della direzione lavori. Ovviamente gli enti di controllo richiederanno maggiori richieste, prescrizioni ed integrazioni a quanto sommariamente elencato. Qui si vuole solo fornire un quadro sintetico e generale, con evidenziate le richieste utili per richiedere ed agevolare l'autorizzazione.

4.3 Domanda e relazione tecnica preliminare

La domanda per i due sistemi comprenderà:

- dati anagrafici del richiedente;
- dati del progettista e della Direzione Lavori (se differente);
- dati indicativi della ditta e/o ditte (con eventuali certificazioni);
- dati significativi dell'impianto (perforazione e installazione);
- dati indicativi sull'ubicazione dell'impianto.

Dovranno poi essere allegati:

- relazione tecnica di progetto;
- corografia ubicativa 1:25 000 e planimetria catastale 1:2 000 ;

componenti	valore	unità di misura
materiale organico (possibilità di sedimentazione)	nessuna	-
valore di pH	$6,5 \div 9$	-
conduttività elettrica	$50 \div 1\,000$	$\mu\,\mathrm{S\,cm^{-1}}$
cloruro	< 300	$\mathrm{mg}\,\ell^{-1}$
ferro e manganese	< 1	$\mathrm{mg}\,\ell^{-1}$
solfato	< 2	$\mathrm{mg}\,\ell^{-1}$
contenuto di O_2	< 2	$\mathrm{mg}\,\ell^{-1}$
cloro	$0 \div 5$	$\mathrm{mg}\,\ell^{-1}$
nitrato	$0 \div 100$	$\mathrm{mg}\,\ell^{-1}$

Tabella 4.1: Requisiti dell'acqua estratta per gli impianti open loop [UNI EN 15450, 2008]

4.3.1 Per sistemi open loop

La relazione tecnica comprenderà:

▶ Dati tecnici

- potenza dell'impianto (kW_t);
- fabbisogno termico mensile, con carico medio e di picco;
- portata necessaria (m^3s^{-1});
- ΔT (K o ℃);
- dotazioni di sicurezza e controllo.

▶ Dati idrogeologici

- controllo dei vincoli esistenti nell'area di indagine;
- inquadramento geologico;
- idrogeologia del sottosuolo (caratteristiche dell'acquifero, permeabilità e direzione di flusso);
- censimento dei pozzi esistenti nell'area e di altre perforazioni:
- analisi qualitativa dell'acqua prelevata e restituita alla falda.

► Progetto

- schema di progetto per la costruzione dei pozzi, con particolare riferimento a diametri e materiali di filtri e rivestimento;
- descrizione sulle metodologie previste per eseguire a regola d'arte la cementazione del foro;
- valutazioni sulle possibili conseguenze relative al prelievo dell'acqua e sulla reimmissione, indicando il ΔT previsto a breve e a lungo termine (il massimo ammesso è di 5 °C) e la compatibilità ambientale dello scarico nel corpo recipiente.

4.3.2 Per sistemi closed loop

La relazione tecnica comprenderà:

► Dati tecnici

- potenza dell'impianto (kW_t);
- fabbisogno termico mensile, con carico medio e di picco;
- fluidi, additivi e anticongelanti che verranno utilizzati;
- ΔT (K o °C);
- dotazioni di sicurezza e controllo.

► Dati idrogeologici

- controllo dei vincoli esistenti nell'area di indagine;
- inquadramento geologico;
- idrogeologia del sottosuolo (caratteristiche dell'acquifero o degli acquiferi attraversati, permeabilità e direzione di flusso);
- censimento dei pozzi esistenti nell'area e di altre perforazioni.

► Progetto

- schema di progetto per la costruzione della sonda o del campo sonde;
- indicazioni specifiche sulla metodologia di perforazione e sui relativi diametri;
- descrizione sulle metodologie previste per eseguire a regola d'arte la cementazione del foro.
- simulazione degli effetti con definizione del tipo, della localizzazione e della quantità della perturbazione termica, a breve e a lungo termine.

4.3.3 Compiti della direzione lavori

Dovrà verificare la corretta esecuzione della posa in opera e controllare che in fase di perforazione la stratigrafia (i cui campioni dovranno essere lasciati a disposizione delle autorità competenti), sia corrispondente a quella prevista in fase di progetto ed in caso contrario predisporre delle adeguate soluzioni tecniche per mitigare le novità emerse.

Dovrà verificare con particolare attenzione gli aspetti relativi alla cementazione, dovendone certificare poi la tenuta. Inoltre eseguirà a seconda dell'impianto realizzato:

- prova di verifica a pressione della tenuta;
- prova di portata nel pozzo di presa e di immissione in quello di scarico.

4.4 Relazione tecnica finale

4.4.1 Per sistemi open loop

Comprenderà:

- dati stratigrafici effettivi;
- schema effettivo dei pozzi realizzati;
- dati idrogeologici derivanti anche dai risultati delle prove di pompaggio eseguite;
- valutazioni sulle possibili conseguenze del prelievo e della restituzione;
- calcolo dell'area influenzata dal ΔT nel breve e lungo termine (bulbo termico).

Verrà allegata:

- la planimetria con le effettive ubicazioni dei pozzi eseguiti con evidenziato il raggio di influenza del ΔT a breve e lungo termine.

La D.L. attesterà mediante dichiarazione sottoscritta la tenuta della cementazione, dell'impianto, la non interferenza tra le falde eventualmente presenti sia tra loro che con la superficie e la compatibilità ambientale dello scarico nel corpo recipiente.

4.4.2 Per sistemi closed loop

Comprenderà:

- dati stratigrafici effettivi;
- schema effettivo dei pozzi realizzati;
- variazioni rispetto al progetto preliminare;
- dati relativi alla cementazione eseguita;
- simulazione effettiva degli effetti con definizione del tipo, della localizzazione e della quantità della perturbazione termica, a breve e a lungo termine.

Verrà allegata:

- la planimetria con le effettive ubicazioni delle sonde eseguite e la perturbazione termica, a breve e a lungo termine.

La D.L. attesterà mediante dichiarazione sottoscritta la tenuta della cementazione e dell'impianto e la non interferenza tra le falde eventualmente presenti, sia tra loro che con la superficie.

Bibliografia

ALLAN, M. L. e PHILIPPACOPOULOS, A. J. (1999), *Properties and performance of cement-based grouts for geothermal heat pump applications*, Office States Department of Energy, Washington, final report ed.

ARMSTEAD, H. e SCHROEDER, C. H. (1983), *Geothermal Energy*, Spon Pr, London.

BANKS, D. (2008), *An Introduction of Thermogeology Ground Source Heating and Cooling*, Blackwell Publishing.

BASTA, S. e MINCHIO, F. (2007), «Geotermia e pompe di calore - Guida pratica agli impianti di climatizzazione», Stampato in proprio, Verona.

BEGAL, F. (1995), *Analisi tecnico-economica di impianti di climatizzazione con accumulo stagionale a terreno*, Tesi di laurea, Facoltà di Ingegneria Gestionale dell'Università di Padova.

BONDESAN, A., FONTANA, A., MOZZI, P. e MENEGHEL, M. (2004), *Geomorfologia della provincia di Venezia. Note illustrative della carta geomorfologica della provincia di Venezia*, Esedra Editrice.

BOSCOLO, C. e MION, F. (2008), «Le acque sotterranee della pianura veneta – I risultati del Progetto SAMPAS», Rap. tecn., Area Tecnico Scientifica – Servizio Acque Interne dell'ARPAV del Veneto.

BRANDL, H. (2006), «Energy foundations and other thermo-active ground structures», *Géotechnique*, vol. 56 (2).

BUSNARDO, E. (2006), *Pompe di calore con sorgente ad acque superficiali o sotterranee: aspetti tecnici, commerciali ed amministrativi*, Tesi di dottorato, Università di Padova – Dipartimento di Tecnica e Gestione dei Sistemi Industriali, relatore prof. R. M. Lazzarin.

CASALE, C., COLLI, G., PENNATI, W. e PETTOROSSI, F. (2009), «Libro bianco sulle pompe di calore», PDF del Gruppo Italiano Pompe di Calore.

CESI (2001), «Applicazioni della tecnologia a pompa di calore nei principali settori industriali», Rap. tecn., SFR-A1/018331.

CLAESSON, J. e ESKILSON, P. (1987), *Thermal Analysis of Heat Extraction Boreholes*, Tesi di dottorato, Department of Mathematical Physics, University of Lund, Sweden.

DA DEPPO, L., DATEI, C., FIOROTTO, V. e SALANDIN, P. (2006), *Acquedotti*, Libreria Internazionale Cortina, Padova, terza ed.

DESIO, A. (2003), *Geologia applicata all'ingegneria*, Hoepli.

DRIGO, V. (2005), «L'anomalia geotermica nella pianura friulana e veneta, una ricchezza da utilizzare e da conservare», Rap. tecn., Collegio degli Ingegneri di Venezia.

EED (2009), *Earth Energy Designer*, sviluppato dalla Blocon software, con la collaborazione di G. Hellström, B. Sanner, J. Claesson, P. Eskilson, Sweden, 3.15 ed.

EGEC (2009), «Geothermal Heat pumps - Ground source Heat pumps», PDF.

ENEA (2003), «La pompa di calore», PDF, collana sviluppo sostenibile.

EUGSTER, W. J. (2009), *Exploitation de la chaleur tirée du sol et du sous-sol*, Office fédéral de l'environnement OFEV.

EURObserv'ER (2009), «Heat pump barometer», L'Observatoire des energies renouvelables.

FANELLI, M. e DICKSON, M. H. (2004), «Geologia e...Geotermia», CNR - Istituto di Geoscienze e Georisorse, Area CNR - Pisa.

FELDERER, G. (2006), «La geotermia nell'Altro Adige», in «Geotermia: applicazioni a bassa temperatura», Fiera di Vicenza.

FERGUSON, G. e WOODBURY, A. (2004), «Subsurface heat flow in an urban environment», *Journal of geophysical research*, vol. 109.

FERNÁNDEZ, A. (2009), «Geothermal Energy in Europe, today and in future», in «European Future Energy Forum 09», EGEC, PDF, Bilbao.

FRANCHETTO, F. (2010), «Impianti geotermici, ecco il decreto di riassetto normativo», *Nextville.it – Energie rinnovabili ed efficienza energetica*.

GUADAGNI, A. e OTHERS (2003), *Prontuario dell'Ingegnere*, Hoepli.

GVP (2006), Hosted by the Global Volcanism Program of the Smithsonian Institution in Washington – DC.

HEINONEN, E. W., TAPSCOTT, R. E., WILDIN, M. W. e BEALL, A. N. (1996), «Assessment of anti-freeze solutions for ground-source heat pump systems», Rap. tecn., New Mexico Engineering Research Institute.

HOCHSTEIN, M. P. (1990), «Classification and assessment of geothermal resources», in UNITAR, curatore, «Small Geothermal Resources: A Guide to Development and Utilization», New York.

IL METEO.IT (2009), «Clima Rovigo - Medie climatiche», .

INGERSOLL, L. R., ZOBEL, O. J. e INGERSOLL, A. C. (1948), *Heat Conduction with Engineering and Geological Application*, McGraw Hill, New York.

LIENAU, P. (1998), *Geothermal Direct Use Engineering and Design Guidebook*, Geo-Heat Center, USA, 3 ed.

LINACRE, E. e GEERTS, B. (1997), *Climates and Weather Explained*, Routledge.

LINDAL, B. (1973), «Industrial and other applications of geothermal energy», in «Geothermal Energy», UNESCO, Paris.

LUBIMOVA, E. A. (1968), «Thermal history of the Earth», in «The Earth's Crust and Upper Mantle», American Geophysical Union.

MARITAN, D. e PANIZZOLO, R. (2008), «Ground Source Heat Pumps Applications in Italy», in «Thirty-Third Workshop on Geothermal Reservoir Engineering», Stanford University, California.

MEHNERT, E. (2004), *The Environmental Effects of Ground-Source Heat Pumps – A Preliminary Overview*, Illinois State Geological Survey, Washington.

MINCHIO, F. (2009), «Veneto tra sonde geotermiche e autorizzazioni», *Energheia Magazine*.

MISSTEAR, B., BANKS, D. e CLARK, L. (2006), *Water Wells and Boreholes*, Wiley, Chichester.

NATIONAL RENEWABLE ENERGY LABORATORY (2009), «2008 Geothermal Technologies market report», Rap. tecn., U.S. Department of Energy.

NOCE, G. (2009), «Test e collaudi di impianti geotermici a pompa di calore», *Strade & Autostrade*, vol. 2.

PATASSINI, D., MUSCO, F. e PICCHIO, S. (2008), «Relazione Ambientale al Documento Preliminare del PTCP della Provincia di Rovigo», Rap. tecn., Provincia di Rovigo e Università IUAV di Venezia – Dipartimento di Pianificazione.

PATASSINI, D., MUSCO, F., PICCHIO, S., CICOLECCHIA, M., FERRO, D. e MAROTTA, L. (2009), «Valutazione Ambientale Strategica (V.A.S.) del Piano Territoriale di Coordinamento Provinciale (P.T.C.P.): Rapporto Ambientale», Rap. tecn., Provincia di Rovigo – Area Territorio e Trasporti, Università IUAV di Venezia – Dipartimento di Pianificazione.

POLLACK, H. N., HURTER, S. J. e JOHNSON, J. R. (1993), «Heat flow from the Earth's interior: Analysis of the global data set», *Geophys*, (31).

PREENE, M. e POWRIE, W. (2009), «Ground energy systems: from analysis to geotechnical design», *Géotechnique*, vol. 59 (3).

RAFFERTY, K. (2001), «Design aspects of commercial open-loop heat pump systems», Rap. tecn., Geo-Heat Center bulletin.

ROSSI, C. (2008), «Linee guida per la disciplina relativa allo sfruttamento dell'energia con sonde geotermiche», in «Geotermia: progettazione e disciplina tecnica», Associazione Nazionale di Idrogeologia e Pozzi Acqua. (Cited at pages 14 e 34)

RYBACH, L. (2003), «Regulatory framework for geothermal in Europe – with special reference to Germany, France, Hungary, Romania, and Switzerland», in «Geothermal training programme», .

SANNER, B. (2001), «Some history of shallow geothermal energy use», in «UNESCO/IGA International Summer School on Direct Application of Geothermal Energy/International Geothermal Days», Germany.

SANNER, B. (2008), «Guidelines, standars, certification and legal permits for ground source heat pumps in the european union», in «9th International IEA Heat Pump Conference», .

SANNER, B. (2009), «Development Of Geothermal Heat Pumps», in «Session VI, Geothermal Heat Pumps. A prospective direction for development in central european region», International Geothermal Days, conference & summer school, Slovakia.

SANNER, B., DUMAS, P., FERNANDEZ, I. e REGUEIRO, M. (2009), «Geotrainet – A new europeanitittive for training and education of planners, drillers and installers of geothermal heat pumps», in «11th Effstock – Thermal Energy Storage for Energy Efficiency and Sustainability», Svezia.

SAVOCA, D. (2008), «Le prospettive di sviluppo delle pompe di calore geotermiche in Lombardia», in «Convegno, Le pompe di calore geotermiche: i vincoli e gli incentivi per lo sviluppo», Milano.

SCAGLIARINI, R. (2005), «E nel Delta del Po fanno trivellazioni illegali», *Corriere Economia*.

SKARPHAGEN, H. (2006), «Ground source heat – heat exchange with the ground: in Norwegian», modulo di elearning sviluppato per l'Università di Oslo.

STACEY, F. D. e LOPER, D. E. (1988), «Thermal history of the Earth: a corollary concerning non-linear mantle rheology», *Physisc Earth Planet International*, (53).

TINTI, F. (2009), «Introduzione alla geotermia», in «Incontro con le aziende: Standard di qualità nella progettazione e realizzazione degli impianti geotermici a sonde verticali», Dipartimento di Ingegneria Chimica, Mineraria e delle Tecnologie Ambientali dell'Università di Bologna, Parco scientifico tecnologico di Venezia VEGA.

UGI (2007), «La Geotermia ieri, oggi, domani», Numero Speciale del Notiziario UGI, Edizioni ETS.

UNI 10349 (1994), «Riscaldamento e raffrescamento degli Edifici - Dati Climatici», Ente Nazionale Italiano di Unificazione.

UNI EN 15450 (2008), «Progettazione degli impianti di riscaldamento a pompa di calore», Ente Nazionale Italiano di Unificazione. (Cited at pages vi, 15 e 35)

UNI EN 378-1 (2008), «Impianti di refrigerazione e pompe di calore – Requisiti di sicurezza e ambientali – Parte 1: Requisiti di base, definizioni, classificazione e criteri di selezione», Ente Nazionale Italiano di Unificazione.

VDI (2000), «VDI 4640 Blatt 1, Thermal use of the underground – Fundamentals, approvals, environmental aspects», Rap. tecn., Verein Deutscher Ingenieure, Düsseldorf.

VDI (2001a), «VDI 4640 Blatt 2, Thermal use of the underground – Ground source heat pump system», Rap. tecn., Verein Deutscher Ingenieure, Düsseldorf.

VDI (2001b), «VDI 4640 Blatt 3, Utilization of the subsurface for thermal purposes: Underground thermal energy storage», Rap. tecn., Verein Deutscher Ingenieure, Düsseldorf.

YOUNGER, P. L. (2006), «Potential pitfalls for water resources of unregulated development of ground-source heat resources», in «Annual Conference of the Chartered Institution of Water – Environmental Management», .

ZARRELLA, A. (2009a), «Le pompe di calore accoppiate al terreno: aspetti termodinamici e funzionali», in «Incontro con le aziende: Impianti geotermici a bassa entalpia e tecniche costruttive», Dipartimento di Fisica Tecnica dell'Università di Padova, Collegio degli Ingegneri della provincia di Padova.

ZARRELLA, A. (2009b), «L'uso del terreno come sorgente termica», Dipartimento di Fisica Tecnica dell'Università di Padova.

Sitografia

- A.N.I.P.A, il portale della perforazione – www.anipapozzi.it
- Edilportale.com, il portale dell'edilizia – www.edilportale.com
- EGEC, European Geothermal Energy Council – www.egec.org
- Geo Heat – geoheat.oit.edu
- Geo Net srl – www.geo-net.it
- IGA, International Geothermal Association – www.geothermal-energy.org
- ScienceDirect – www.sciencedirect.com
- SpringerLink – www.springerlink.com
- Therm-tech Technological Engineering – www.therm-tech.it
- UGI, Unione Geotermica Italiana – www.unionegeotermica.it
- Wikipedia – www.wikipedia.org

- A.N.I.P.A, il portale della perforazione – www.anipapozzi.it
- Edilportale.com, il portale dell'edilizia – www.edilportale.com
- EGEC, European Geothermal Energy Council – www.egec.org
- Geo Heat – geoheat.oit.edu
- Geo Net srl – www.geo-net.it
- IGA, International Geothermal Association – www.geothermal-energy.org
- ScienceDirect – www.sciencedirect.com
- SpringerLink – www.springerlink.com
- Therm-tech Technological Engineering – www.therm-tech.it
- UGI, Unione Geotermica Italiana – www.unionegeotermica.it
- Wikipedia – www.wikipedia.org

- A.N.I.P.A, il portale della perforazione – `www.anipapozzi.it`
- Edilportale.com, il portale dell'edilizia – `www.edilportale.com`
- EGEC, European Geothermal Energy Council – `www.egec.org`
- Geo Heat – `geoheat.oit.edu`
- Geo Net srl – `www.geo-net.it`
- IGA, International Geothermal Association – `www.geothermal-energy.org`
- ScienceDirect – `www.sciencedirect.com`
- SpringerLink – `www.springerlink.com`
- Therm-tech Technological Engineering – `www.therm-tech.it`
- UGI, Unione Geotermica Italiana – `www.unionegeotermica.it`
- Wikipedia – `www.wikipedia.org`

Ringraziamenti

Il primo ringraziamento va a mia mamma, che mi ha dato la possibilità, per nulla scontata, di intraprendere e portare a termine questo percorso universitario, sostenendomi nei momenti di difficoltà.

Un altro importantissimo ringraziamento va ad Eliana, la mia ragazza, che mi è stata sempre vicina e mi ha supportato ed aiutato.

Vorrei ringraziare il Prof. Ursino, che mi ha accompagnato nel lavoro di tesi seguendomi costantemente con estrema disponibilità, e il dottorando, Gianluca Bonifazi, che mi ha aiutato nella parte implementativa del lavoro.

Ringrazio di cuore i miei compagni di studio: Michele, Albo, Gatto, Kevin, Lorenzo e Chiara, per il supporto che mi hanno fornito in questi anni. Soprattutto ringrazio Michele, che, nonostante la pandemia, è stato sempre disponibile per studiare e superare i vari ostacoli insieme. Un ulteriore ringraziamento va ad Albo, perché grazie a lui sono riuscito a finire il percorso universitario in forma, con gli allenamenti eseguiti insieme anche a distanza.